

PRÁCTICO N°2: COMPACTADORES

1. Sean los siguientes códigos:

s	p_i	a	b	c	d	e	f
s_1	3/8	000	0	0	0	0	0
s_2	1/4	001	01	10	10	10	100
s_3	1/8	010	011	110	110	1100	101
s_4	1/8	011	0111	1110	1110	1101	110
s_5	1/16	100	01111	11110	1011	1110	111
s_6	1/16	101	011111	111110	1101	1111	001

a. Clasificar cada uno de ellos (Bloque, No singular, Instantáneos, Unívocamente decodificables).

- **Columna A:** Se clasifica como **código de bloque, instantáneo, no singular y unívocamente decodificable**. Esto se debe a que todos los códigos tienen una longitud fija de 3 bits, ninguno es prefijo de otro, son todos distintos y, al mantener la misma longitud, no existe posibilidad de confusión al formar palabras.
- **Columna B:** Se clasifica como **unívocamente decodificable y no singular**. Aunque existen códigos que son prefijos de otros, cualquier palabra construida puede identificarse sin ambigüedades. Además, cada símbolo tiene un código distinto.
- **Columna C:** Se clasifica como **instantáneo, unívocamente decodificable y no singular**. Ningún código es prefijo de otro, lo que permite decodificación inmediata; al mismo tiempo, todos los códigos son diferentes y la secuencia resultante siempre se puede reconstruir sin confusión.
- **Columna D:** Se clasifica como **singular**, ya que existen símbolos distintos que comparten el mismo código.
- **Columna E:** Se clasifica como **unívocamente decodificable y no singular**. Pese a no ser instantáneo, las palabras generadas pueden interpretarse de manera única, y cada símbolo mantiene un código propio.
- **Columna F:** Se clasifica como **singular**, ya que existen símbolos distintos que comparten el mismo código.

b. Calcular la longitud promedio de los unívocamente decodificables.

$$L_a = \sum_{i=1}^q p(s_i) \times l(s_i) = 3 \cdot \frac{3}{8} + 3 \cdot \frac{1}{4} + 3 \cdot \frac{1}{8} + 3 \cdot \frac{1}{8} + 3 \cdot \frac{1}{16} + 3 \cdot \frac{1}{16} = 3 \text{ bits}$$

$$L_b = \sum_{i=1}^q p(s_i) \times l(s_i) = 1 \cdot \frac{3}{8} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{8} + 4 \cdot \frac{1}{8} + 5 \cdot \frac{1}{16} + 6 \cdot \frac{1}{16} = 2,4375 \text{ bits}$$

$$L_c = \sum_{i=1}^q p(s_i) \times l(s_i) = 1 \cdot \frac{3}{8} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{8} + 4 \cdot \frac{1}{8} + 5 \cdot \frac{1}{16} + 6 \cdot \frac{1}{16} = 2,4375 \text{ bits}$$

$$L_e = \sum_{i=1}^q p(s_i) \times l(s_i) = 1 \cdot \frac{3}{8} + 2 \cdot \frac{1}{4} + 4 \cdot \frac{1}{8} + 4 \cdot \frac{1}{8} + 4 \cdot \frac{1}{16} + 4 \cdot \frac{1}{16} = 2,375 \text{ bits}$$

2. Ejercicios

Longitud palabra →	1	2	3	4	5
Código A	1	2	3	1	2
Código B	0	4	3	2	2
Código C	2	3	5	1	0
Código D	1	2	2	3	2

a. ¿Cuál de los conjuntos de longitudes de la siguiente tabla es válida para un código unívocamente decodificable con base $X\{0,1,2\}$?

$$\sum_{i=1}^q r^{-l_i} \leq 1$$

Código A:

$$\sum_{i=1}^q r^{-l_i} = 3^{-1} + 2 \cdot 3^{-2} + 3 \cdot 3^{-3} + 3^{-4} + 2 \cdot 3^{-5} = 0,6872 \leq 1$$

Código B:

$$\sum_{i=1}^q r^{-l_i} = 4 \cdot 3^{-2} + 3 \cdot 3^{-3} + 2 \cdot 3^{-4} + 2 \cdot 3^{-5} = 0,5884 \leq 1$$

Código C:

$$\sum_{i=1}^q r^{-l_i} = 2 \cdot 3^{-1} + 3 \cdot 3^{-2} + 5 \cdot 3^{-3} + 3^{-4} = 1,1975 > 1$$

Código D:

$$\sum_{i=1}^q r^{-l_i} = 3^{-1} + 2 \cdot 3^{-2} + 2 \cdot 3^{-3} + 3 \cdot 3^{-4} + 2 \cdot 3^{-5} = 0,6748 \leq 1$$

- b. Construir un código instantáneo con cada conjunto de longitudes válidas.

Código A

Dada una fuente $A = a_1, a_2, a_3, \dots, a_{11}$; $V = q = 11$, se pretende construir un código instantáneo para los 11 símbolos, con una base $r = 3$.

Se toman $n_1 \leq 3$ palabras de longitud 1, por ejemplo $n_1 = 2$.

Quedan $3^2 - 2 \cdot 3 = 3$ posibles prefijos de longitud 2, $n_2 \leq 3^2 - 2 \cdot 3 = 3$, tomamos $n_2 = 2$ prefijos de longitud 2.

Quedan $3^3 - 2 \cdot 3^2 - 2 \cdot 3 = 3$ posibles prefijos de longitud 3, $n_3 \leq 3^3 - 2 \cdot 3^2 - 2 \cdot 3 = 3$, tomamos $n_3 = 2$ prefijos de longitud 3.


Quedan $3^4 - 2 \cdot 3^3 - 2 \cdot 3^2 - 2 \cdot 3 = 3$ posibles prefijos de longitud 4, $n_4 \leq 3^4 - 2 \cdot 3^3 - 2 \cdot 3^2 - 2 \cdot 3 = 3$, tomamos $n_4 = 2$ prefijos de longitud 4.

Quedan $3^5 - 2 \cdot 3^4 - 2 \cdot 3^3 - 2 \cdot 3^2 - 2 \cdot 3 = 3$ posibles prefijos de longitud 5, $n_5 \leq$

$3^5 - 2 \cdot 3^4 - 2 \cdot 3^3 - 2 \cdot 3^2 - 2 \cdot 3 = 3$, tomamos $n_5 = 3$ prefijos de longitud 5, completando el código para los 11 símbolos.

Luego el código es:

Código A		
Símbolo	Código	Longitud
a_1	0	1
a_2	1	1
a_3	20	2
a_4	21	2
a_5	220	3
a_6	221	3
a_7	2220	4
a_8	2221	4
a_9	22220	5
a_{10}	22221	5
a_{11}	22222	5



Código B

Dada una fuente $B = b_1, b_2, b_3, \dots, b_{11}$; $V = q = 11$, se pretende construir un código instantáneo para los 11 símbolos, con una base $r = 3$.


Se toman $n_1 \leq 3$ palabras de longitud 1, por ejemplo $n_1 = 1$.

Quedan $3^2 - 1 \times 3 = 6$ posibles prefijos de longitud 2, $n_2 \leq 3^2 - 1 \times 3 = 6$, tomamos $n_2 = 4$ prefijos de longitud 2.

Quedan $3^3 - 1 \times 3^2 - 4 \times 3 = 12$ posibles prefijos de longitud 3, $n_3 \leq 3^3 - 1 \times 3^2 - 4 \times 3 = 12$, tomamos $n_3 = 6$ prefijos de longitud 3, completando el código para los 11 símbolos.

Luego el código es:

Código B		
Símbolo	Código	Longitud
b_1	0	1
b_2	10	2
b_3	11	2
b_4	12	2
b_5	20	2
b_6	210	3
b_7	211	3
b_8	212	3
b_9	220	3
b_{10}	221	3
b_{11}	222	3



Código D


Dada una fuente $D = d_1, d_2, d_3, \dots, d_{10}$; $V = q = 10$, se pretende construir un código instantáneo para los 10 símbolos, con una base $r = 3$.

Se toman $n_2 \leq 3^2 = 9$ palabras de longitud 2, por ejemplo $n_2 = 8$.

Quedan $3^3 - 0 \times 3^2 - 8 \times 3 = 3$ posibles prefijos de longitud 3, $n_3 \leq 3^3 - 0 \times 3^2 - 8 \times 3 = 3$, tomamos $n_3 = 2$ prefijos de longitud 2, completando el código para los 10 símbolos.

Luego el código es:

Código D		
Símbolo	Código	Longitud
d_1	00	2
d_2	01	2
d_3	02	2
d_4	10	2
d_5	11	2
d_6	12	2
d_7	20	2
d_8	21	2
d_9	220	3
d_{10}	221	3



3. Demostrar que el código coma cumple Kraft.

Planteo

- Alfabeto de tamaño D y elegimos un símbolo especial c (la coma).
- Un código coma es un conjunto de palabras de la forma:

$$\mathcal{C} = \{u_i c : u_i \in (\Sigma \setminus \{c\})^*, i \in I\}$$

O sea, todas terminan en c y c no aparece dentro del "cuerpo" u_i .

- La longitud del código $u_i c$ es $\ell_i = |u_i| + 1$.

Queremos probar:

$$\sum_{i \in I} D^{-\ell_i} \leq 1 \text{ (desigualdad de Kraft)}$$

Demostración 1

- Prefijo: Como el primer c que aparece en cualquier palabra marca el fin del código, ninguna palabra puede ser prefijo de otra (si una fuese prefijo de otra, el c de la corta aparecería dentro de la larga, prohibido) $\Rightarrow \mathcal{C}$ es código prefijo.
- Kraft-McMillan (necesaria para prefijos):

Todo código prefijo sobre un alfabeto D -ario satisface:

$$\sum_i D^{-\ell_i} \leq 1$$

Como $\mathcal{C}$ es prefijo, cumple Kraft. ■

Demostración 2

Agrupemos por la longitud del “cuerpo” $m = |u_i|$. Para cada $m \geq 0$:

- Los cuerpos u se forman sin usar $c \rightarrow$ hay a lo sumo $(D - 1)^m$ distintos.
- Cada palabra de la forma uc tiene longitud $\ell = m + 1$ y aporta $D^{-(m+1)}$ a la suma de Kraft.

Por lo tanto:

$$\sum_{i \in I} D^{-\ell_i} = \sum_{m \geq 0} \sum_{i: |u_i|=m} D^{-(m+1)} \leq \sum_{m \geq 0} (D - 1)^m D^{-(m+1)}$$

La suma de la derecha es una geométrica:

$$\sum_{m \geq 0} \frac{(D - 1)^m}{D^{m+1}} = \frac{1}{D} \sum_{m \geq 0} \left(\frac{D - 1}{D} \right)^m = \frac{1}{D} \cdot \frac{1}{1 - \frac{D - 1}{D}} = \frac{1}{D} \cdot \frac{1}{\frac{1}{D}} = 1$$

Luego $\sum_i D^{-\ell_i} \leq 1$. ■

4. Sea un código ternario (*base $q = 3$*). Se desea codificar los 10 dígitos decimales con las longitudes (en trits):

$$\ell = \{1, 1, 2, 2, 3, 3, 3, 4, 4\}$$

- a. Verificar con Kraft si es posible codificar los 10 dígitos.

$$\sum_i 3^{-\ell_i} \leq 1$$

$$2 \cdot 3^{-1} + 2 \cdot 3^{-2} + 4 \cdot 3^{-3} + 2 \cdot 3^{-4} = \frac{2}{3} + \frac{2}{9} + \frac{4}{27} + \frac{2}{81} = \frac{86}{81} > 1$$

No es posible codificar los 10 dígitos con ese multiconjunto de longitudes.

- b. Si no fuera posible, indicar cuántos dígitos como máximo se podrían codificar manteniendo esas longitudes (es decir, eliminando la menor cantidad de palabras).

El exceso actual es $\frac{86}{81} - 1 = \frac{5}{81}$. Quitando una sola palabra de longitud 2 (aporta $3^{-2} = \frac{1}{9} = \frac{9}{81}$), ya baja de 1:

$$2 \cdot 3^{-1} + 1 \cdot 3^{-2} + 4 \cdot 3^{-3} + 2 \cdot 3^{-4} = \frac{2}{3} + \frac{1}{9} + \frac{4}{27} + \frac{2}{81} = \frac{77}{81} \leq 1$$

Con quitar sólo 1 palabra (de las de longitud 2) alcanzan.


Máximo codificable: $10 - 1 = 9$ dígitos.

- c. Construir un árbol de codificación (o dar un ejemplo de código prefijo) para el caso máximo posible.

Usamos alfabeto $\{0, 1, 2\}$:

- Longitud 1: $s_1 = 0$; $s_2 = 1$
- Longitud 2: $s_3 = 20$
- Longitud 3: $s_4 = 210$; $s_5 = 211$; $s_6 = 212$; $s_7 = 220$
- Longitud 4: $s_8 = 2210$; $s_9 = 2211$

Luego el árbol es:




5. Sean los siguientes textos:

PABLOPABLITOCLAVOUNCLAVITO
COMOQUIERESQUETEQUIERASIQUIENQUIEROQUEMEQUIERA

- a. Realizar la codificación usando los siguientes métodos:

Huffman

Diagrama de Huffman:



Símbolo	Frecuencia	Probabilidad	Código	Longitud
A	4	$\frac{4}{26} \approx 0,1538$	10	2
L	4	$\frac{4}{26} \approx 0,1538$	011	3
O	4	$\frac{4}{26} \approx 0,1538$	010	3
B	2	$\frac{2}{26} \approx 0,0769$	110	3
C	2	$\frac{2}{26} \approx 0,0769$	1111	4
I	2	$\frac{2}{26} \approx 0,0769$	1110	4
P	2	$\frac{2}{26} \approx 0,0769$	0001	4
T	2	$\frac{2}{26} \approx 0,0769$	0000	4
V	2	$\frac{2}{26} \approx 0,0769$	0011	4
N	1	$\frac{1}{26} \approx 0,0385$	00101	5
U	1	$\frac{1}{26} \approx 0,0385$	00100	5

000110110011010000110110011111000000101111011100011010
0010000101111101110001111100000010

- Bits totales: 88 *bits*
- Longitud Media:

$$L = \sum_{i=1}^q p(s_i) \cdot l(s_i)$$

$$L = 0,1538 \cdot 2 + 2 \cdot (0,1538 \cdot 3) + 0,0769 \cdot 3 + 5 \cdot (0,0769 \cdot 4) + 2 \cdot (0,0385 \cdot 5) = \frac{44}{13} \approx 3,38 \text{ bits}$$

- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 26 \times 8 = 208 \text{ bits}$

$$\left(1 - \frac{88}{208}\right) \cdot 100\% = 57,69\%$$

Texto: **COMOQUIERESQUETEQUIERASIQUIENQUIEROQUEMEQUIERA**

Tabla de Códigos:

Símbolo	Frecuencia	Probabilidad	Código	Longitud
<i>E</i>	10	$\frac{10}{46} \approx 0,2174$	01	2
<i>I</i>	6	$\frac{6}{46} \approx 0,1304$	100	3
<i>Q</i>	7	$\frac{7}{46} \approx 0,1522$	101	3
<i>U</i>	7	$\frac{7}{46} \approx 0,1522$	110	3
<i>A</i>	2	$\frac{2}{46} \approx 0,0435$	0001	4
<i>O</i>	3	$\frac{3}{46} \approx 0,0652$	0011	4
<i>R</i>	4	$\frac{4}{46} \approx 0,0870$	1111	4
<i>S</i>	2	$\frac{2}{46} \approx 0,0435$	0000	4
<i>C</i>	1	$\frac{1}{46} \approx 0,0217$	00100	5
<i>M</i>	2	$\frac{2}{46} \approx 0,0435$	11101	5
<i>N</i>	1	$\frac{1}{46} \approx 0,0217$	11100	5
<i>T</i>	1	$\frac{1}{46} \approx 0,0217$	00101	5

- Bits totales: 149 *bits*
- Longitud Media: $L \approx 3,239 \text{ bits}$
- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 46 \times 8 = 368 \text{ bits}$

$$\left(1 - \frac{149}{368}\right) \cdot 100\% = 59,51\%$$

Shannon

Texto: **PABLOPABLITOCLAVOUNCLAVITO.**

Símbolo	Frecuencia	$p(s_i)$	FA (previos)	Decimal	Binario	Longitud	Código
A	4	$\frac{4}{26} \approx 0,1538$	$\frac{0}{26}$	0.000	0.000	3	000
L	4	$\frac{4}{26} \approx 0,1538$	$\frac{4}{26}$	0.154	0.001	3	001
O	4	$\frac{4}{26} \approx 0,1538$	$\frac{8}{26}$	0.308	0.010	3	010
B	2	$\frac{2}{26} \approx 0,0769$	$\frac{12}{26}$	0.462	0.0111	4	0111
C	2	$\frac{2}{26} \approx 0,0769$	$\frac{14}{26}$	0.538	0.1000	4	1000
I	2	$\frac{2}{26} \approx 0,0769$	$\frac{16}{26}$	0.615	0.1001	4	1001
P	2	$\frac{2}{26} \approx 0,0769$	$\frac{18}{26}$	0.692	0.1011	4	1011
T	2	$\frac{2}{26} \approx 0,0769$	$\frac{20}{26}$	0.769	0.1100	4	1100
V	2	$\frac{2}{26} \approx 0,0769$	$\frac{22}{26}$	0.846	0.1101	4	1101
N	1	$\frac{1}{26} \approx 0,0385$	$\frac{24}{26}$	0.923	0.11101	5	11101
U	1	$\frac{1}{26} \approx 0,0385$	$\frac{25}{26}$	0.962	0.11110	5	11110

- Bits Totales: 94 *bits*
- Longitud Media: $L \approx 3,615$ *bits*
- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 26 \times 8 = 208$ *bits*
$$\left(1 - \frac{94}{208}\right) \cdot 100\% = 54,81\%$$

Texto: **COMOQUIERESQUETEQUIERASIQUIENQUIEROQUEMEQUIERA.**


Símbolo	Frecuencia	$p(s_i)$	FA (previos)	Decimal	Binario	Longitud	Código
E	10	$\frac{10}{46} \approx 0,2174$	$\frac{0}{46}$	0.000	0.000	3	000
I	6	$\frac{6}{46} \approx 0,1304$	$\frac{10}{46}$	0.217	0.001	3	001
Q	7	$\frac{7}{46} \approx 0,1522$	$\frac{17}{46}$	0.370	0.010	3	010
U	7	$\frac{7}{46} \approx 0,1522$	$\frac{24}{46}$	0.522	0.100	3	100
A	2	$\frac{2}{46} \approx 0,0435$	$\frac{30}{46}$	0.652	0.1010	4	1010

<i>O</i>	3	$\frac{3}{46} \approx 0,0652$	$\frac{34}{46}$	0.739	0.1011	4	1011
<i>R</i>	4	$\frac{4}{46} \approx 0,0870$	$\frac{37}{46}$	0.804	0.11001	5	11001
<i>S</i>	2	$\frac{2}{46} \approx 0,0435$	$\frac{39}{46}$	0.848	0.11011	5	11011
<i>C</i>	1	$\frac{1}{46} \approx 0,0217$	$\frac{41}{46}$	0.891	0.11100	5	11100
<i>M</i>	2	$\frac{2}{46} \approx 0,0435$	$\frac{43}{46}$	0.935	0.111011	6	111011
<i>N</i>	1	$\frac{1}{46} \approx 0,0217$	$\frac{44}{46}$	0.957	0.111101	6	111101
<i>T</i>	1	$\frac{1}{46} \approx 0,0217$	$\frac{45}{46}$	0.978	0.111110	6	111110

- Bits Totales: 166 *bits*
- Longitud Media: $L \approx 3,609$ *bits*
- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 46 \times 8 = 368$ *bits*
$$\left(1 - \frac{166}{368}\right) \cdot 100\% = 54,89\%$$

Fano

Texto: **PABLOPABLITOC LAVOUNCLAVITO.**



Símbolo	Frecuencia	Probabilidad	Código	Longitud
A	4	$\frac{4}{26} \approx 0,1538$	00	2

L	4	$\frac{4}{26} \approx 0,1538$	010	3
O	4	$\frac{4}{26} \approx 0,1538$	011	3
B	2	$\frac{2}{26} \approx 0,0769$	100	3
C	2	$\frac{2}{26} \approx 0,0769$	1010	4
I	2	$\frac{2}{26} \approx 0,0769$	1011	4
P	2	$\frac{2}{26} \approx 0,0769$	1100	4
T	2	$\frac{2}{26} \approx 0,0769$	1101	4
V	2	$\frac{2}{26} \approx 0,0769$	1110	4
N	1	$\frac{1}{26} \approx 0,0385$	11110	5
U	1	$\frac{1}{26} \approx 0,0385$	11111	5

- Bits Totales: 88 *bits*
- Longitud Media: $L \approx 3,38 \text{ bits}$
- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 26 \times 8 = 208 \text{ bits}$
$$\left(1 - \frac{88}{208}\right) \cdot 100\% = 57,69\%$$

Texto: **COMOQUIERESQUETEQUIERASIQUIENQUIEROQUEMEQUIERA**

Símbolo	Frecuencia	Probabilidad	Código	Longitud
E	10	$\frac{10}{46} \approx 0,2174$	00	2
Q	7	$\frac{7}{46} \approx 0,1522$	010	3
U	7	$\frac{7}{46} \approx 0,1522$	011	3
I	6	$\frac{6}{46} \approx 0,1304$	100	3
R	4	$\frac{4}{46} \approx 0,0870$	101	3
O	3	$\frac{3}{46} \approx 0,0652$	1100	4
A	2	$\frac{2}{46} \approx 0,0435$	1101	4
S	2	$\frac{2}{46} \approx 0,0435$	11100	5
M	2	$\frac{2}{46} \approx 0,0435$	11101	5
C	1	$\frac{1}{46} \approx 0,0217$	11110	5
N	1	$\frac{1}{46} \approx 0,0217$	111110	6
T	1	$\frac{1}{46} \approx 0,0217$	111111	6

- Bits Totales: 149 *bits*
- Longitud Media: $L \approx 3,239 \text{ bits}$
- Porcentaje de Compresión:

- Texto original: 8 *bits* por símbolo $\rightarrow 46 \times 8 = 368 \text{ bits}$

$$\left(1 - \frac{149}{368}\right) \cdot 100\% = 59,51\%$$

ii. Dinámicos: LZ – LZW – Huffman – Aritmético.

LZ

Texto: **PABLOPABLITOC LAVOUNCLAVITO**

El tamaño de la ventana será de 16 *bits*, ya que con eso alcanza para referenciar patrones como PABLITO desde PABLO, o CLAVITO desde CLAVO.

Comenzamos con una ventana de tamaño 0, seguida de 1, y así sucesivamente. En la gráfica se muestra la ventana de 16 completa para mostrar el máximo texto que toma la ventana.



Un token es una tupla que indica cómo reconstruir parte del texto:

- Si se encuentra el carácter: (1, ASCII del carácter)
- Si no se encuentra el carácter: (0, posición absoluta dentro de la ventana, longitud)

Paso	Token	Ventana (lo ya emitido, máx. 16)	Expande
1	(1,'P')		P
2	(1,'A')	P	A
3	(1,'B')	PA	B
4	(1,'L')	PAB	L
5	(1,'O')	PABL	O
6	(0,1,4)	PABLO	PABL
7	(1,'I')	PABLOPABL	I
8	(1,'T')	PABLOPABLI	T
9	(0,5,1)	PABLOPABLIT	O
10	(1,'C')	PABLOPABLITO	C
11	(0,4,1)	ABLOPABLITOC	L
12	(0,2,1)	BLOPABLITOC	A
13	(1,'V')	LOPABLITOC	V
14	(0,5,1)	OPABLITOC	O
15	(1,'U')	PABLITOC	U
16	(1,'N')	ABLITOC	N
17	(0,10,4)	BLITOC	CLAV
18	(0,3,3)	ITOC	ITO

- Secuencia final de tokens:
(1,'P') (1,'A') (1,'B') (1,'L') (1,'O') (0,1,4) (1,'I') (1,'T') (0,5,1) (1,'C') (0,4,1) (0,2,1) (1,'V') (0,5,1) (1,'U') (1,'N') (0,10,4) (0,3,3)
- Bits totales: 162 *bits*
- Longitud Media: $L \approx 6,23 \text{ bits}$
- Porcentaje de Compresión:

- Texto original: 8 *bits* por símbolo $\rightarrow 26 \times 8 = 208 \text{ bits}$

$$\left(1 - \frac{162}{208}\right) \cdot 100\% = 22,11\%$$

Texto: **COMOQUIERESQUETEQUIERASIQUIENQUIEROQUEMEQUIERA.**

Paso	Token	Ventana (máx. 16)	Expande
1	(1,'C')		C
2	(1,'O')	C	O
3	(1,'M')	CO	M
4	(0,2,1)	COM	O
5	(1,'Q')	COMO	Q
6	(1,'U')	COMOQ	U
7	(1,'I')	COMOQU	I
8	(1,'E')	COMOQUI	E
9	(1,'R')	COMOQUIE	R
10	(0,8,1)	COMOQUIER	E
11	(1,'S')	COMOQUIERE	S
12	(0,5,2)	OMOQUIERES	QU
13	(0,8,1)	MOQUIERESQU	E
14	(1,'T')	QUIERESQUE	T
15	(0,8,1)	IERESQUET	E
16	(0,5,5)	RESQUETE	QUIER
17	(1,'A')	ESQUETEQUIER	A
18	(0,5,1)	SQUETEQUIERA	S
19	(0,12,1)	QUETEQUIERAS	I
20	(0,9,4)	ETEQUIERASI	QUIE
21	(1,'N')	TEQUIERASIQ UIE	N
22	(0,4,5)	QUIERASIN	QUIER
23	(1,'O')	IERASINQUIER	O
24	(0,6,2)	RASINQUIERO	QU
25	(0,7,1)	ASINQUIEROQU	E
26	(1,'M')	SINQUIEROQUE	M
27	(0,5,1)	INQUIEROQUEM	E
28	(0,6,5)	NQUIEROQUEME	QUIER

- Secuencia final de tokens:
(1,'C') (1,'O') (1,'M') (0,2,1) (1,'Q') (1,'U') (1,'I') (1,'E') (1,'R') (0,8,1) (1,'S') (0,5,2) (0,8,1) (1,'T') (0,8,1) (0,5,5) (1,'A') (0,5,1) (0,12,1) (0,9,4) (1,'N') (0,4,5) (1,'O') (0,6,2) (0,7,1) (1,'M') (0,5,1) (0,6,5) (1,'A')

- Bits totales: 261 *bits*
- Longitud Media: $L \approx 6,57 \text{ bits}$
- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 46 \times 8 = 368 \text{ bits}$

$$\left(1 - \frac{261}{368}\right) \cdot 100\% = 29,08\%$$

LZW (Lempel Ziv Welch)

Texto: **PABLOPABLITOC LAVOUNCLAVITO.**

Paso	W	k	Salida	Nueva entrada	Código
1	P	A	'P' (80)	PA	256
2	A	B	'A' (65)	AB	257
3	B	L	'B' (66)	BL	258
4	L	O	'L' (76)	LO	259
5	O	P	'O' (79)	OP	260
6	PA	B	[256]	PAB	261
7	BL	I	[258]	BLI	262
8	I	T	'I' (73)	IT	263
9	T	O	'T' (84)	TO	264
10	O	C	'O' (79)	OC	265
11	C	L	'C' (67)	CL	266

12	L	A	'L' (76)	LA	267
13	A	V	'A' (65)	AV	268
14	V	O	'V' (86)	VO	269
15	O	U	'O' (79)	OU	270
16	U	N	'U' (85)	UN	271
17	N	C	'N' (78)	NC	272
18	CL	A	[266]	CLA	273
19	AV	I	[268]	AVI	274
20	IT	O	[263]	ITO	275
21	O	—	'O' (79)		

- Bits totales: 189 *bits*
- Longitud Media: $L \approx 7,27 \text{ bits}$
- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 26 \times 8 = 208 \text{ bits}$
$$\left(1 - \frac{189}{208}\right) \cdot 100\% = 9,13\%$$

Texto: **COMOQUIERESQUETEQUIERASIQUIENQUIEROQUEMEQUIERA.**

Paso	W	k	Salida	Nueva entrada	Código
1	C	O	'C' (67)	CO	256
2	O	M	'O' (79)	OM	257
3	M	O	'M' (77)	MO	258
4	O	Q	'O' (79)	OQ	259
5	Q	U	'Q' (81)	QU	260
6	U	I	'U' (85)	UI	261
7	I	E	'I' (73)	IE	262
8	E	R	'E' (69)	ER	263
9	R	E	'R' (82)	RE	264
10	E	S	'E' (69)	ES	265
11	S	Q	'S' (83)	SQ	266
12	QU	E	[260]	QUE	267
13	E	T	'E' (69)	ET	268
14	T	E	'T' (84)	TE	269
15	E	Q	'E' (69)	EQ	270
16	QU	I	[260]	QUI	271
17	IE	R	[262]	IER	272
18	R	A	'R' (82)	RA	273
19	A	S	'A' (65)	AS	274
20	S	I	'S' (83)	SI	275
21	I	Q	'I' (73)	IQ	276
22	QUI	E	[271]	QUIE	277
23	E	N	'E' (69)	EN	278
24	N	Q	'N' (78)	NQ	279
25	QUIE	R	[277]	QUIER	280
26	R	O	'R' (82)	RO	281
27	OQ	U	[259]	OQU	282
28	U	E	'U' (85)	UE	283
29	E	M	'E' (69)	EM	284
30	M	E	'M' (77)	ME	285
31	EQ	U	[270]	EQU	286
32	UI	E	[261]	UIE	287
33	ER	A	[263]	ERA	288

- Bits totales: 306 *bits*
- Longitud Media: $L \approx 6,65 \text{ bits}$

- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 46 \times 8 = 368 \text{ bits}$

$$\left(1 - \frac{306}{368}\right) \cdot 100\% = 16,85\%$$

Huffman Dinámico

Texto: PABLOPABLITOCLAVOUNCLAVITO


Al tener 11 símbolos posibles, el transmisor envía cada símbolo codificado en 4 bits, ya que $2^4 = 16$ caracteres posibles.

Es así, que tenemos como transmisor:

Carácter	Código
A	0000
B	0001
C	0010
I	0011
L	0100
N	0101
O	0110
P	0111
T	1000
U	1001
V	1010

PABLOPABLITOCLAVOUNCLAVITO

Leemos P




Emisor = 0111

Receptor = i0, P₁, 1

Codificación:
0111

Leemos A




Emisor = 0 0000

Receptor = i0, A₁, 1, P₁, 2

Codificación:
0111 0 0000

Leemos B




Emisor = 00 0001

Receptor = i0, B₁, 1, A₁, 2, P₁, 3

Codificación:
0111 0 0000 00 0001

Ordenamos (Para mantener la propiedad Sibling)




Emisor = 00 0001

Receptor = i0, B₁, 1, A₁, P₁, 2, 3


Codificación:
0111 0 0000 00 0001

Leemos L

Receptor = i0, L₁, 1,
B₁, 2, A₁, P₁, 3, 4




Ordenamos




Receptor = $i0, L_1, 1, B_1, P_1, A_1, 2, 2, 4$

Leemos O




Receptor = $i0, O_1, 1, L_1, 2, B_1, P_1, A_1, 3, 2, 5$

Ordenamos




Receptor = $i0, O_1, 1, L_1, A_1, B_1, P_1, 2, 3, 2, 5$


Leemos P




Leemos A



Ordenamos




Leemos B




Receptor = i0, O₁, 1,
L₁, B₂, A₂, P₂, 2, 4, 4,
8

Leemos L




Receptor = i0, O₁, 1,
L₂, B₂, A₂, P₂, 3, 4, 5,
9

Leemos I




Receptor = i0, I1, 1,
O1, 2, L2, B2, A2, P2,
4, 4, 6, 10

Leemos T




Receptor = i0, T1, 1, I1,
2, O1, 3, L2, B2, A2, P2,
5, 4, 7, 11

Ordenamos



Receptor = i0, T1, 1,
I1, O1, 2, P2, L2, B2, A2, 3, 4, 4, 7, 11

Y continuamos así, hasta consumir toda la cadena:



Obtenemos como receptor final:

N1 U1 B2 C2 I2 P2 T2 V2 2 A4 L4 O4 4 4 4 4 8 8 8 10 16 26

Y como codificación final:


0111000000000010000100000001101010010100000001100000010001000000000
10010001000000001010010100100101000010101100000010000

- Bits totales: 137 bits
- Longitud Media: $L \approx 5,269$ bits
- Porcentaje de Compresión:

○ Texto original: 8 bits por símbolo $\rightarrow 26 \times 8 = 208$ bits

$$\left(1 - \frac{137}{208}\right) \cdot 100\% = 34,13\%$$

Aplicando el mismo procedimiento para el texto:
 COMOQUIERESQUETEQUIERASIQUIENQUIEROQUEMEQUIERA



Obtenemos como receptor final:

$C_1 T_1 N_1 M_2 S_2 A_2 2 O_3 3 R_4 4 5 I_6 Q_7 U_7 7 9 E_{10} 13 14 19 27 46$

Y como codificación final:

0010000111110100111011101000111110100001011100100
 10101101110100011111000100001001011100101111010001111100010000100

- Bits totales: 149 *bits*
- Longitud Media: $L \approx 3,239 \text{ bits}$
- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 46 \times 8 = 368 \text{ bits}$

$$\left(1 - \frac{149}{368}\right) \cdot 100\% = 59,51\%$$

Codificación Aritmética

Para obtener las nuevas cotas se utiliza:

$$L = L - 1 + R - 1 * F(s_i)$$

$$H = L - 1 + R - 1 * F^+(s_i)$$

Donde L-1 es la cota inferior anterior, R-1 el rango, y F el acumulado inferior de la probabilidad del símbolo, y F⁺ el superior.

Aplicándolo para el texto: **PABLOPABLITOC LAVOUNCLAVITO**

i	T	L_anterior	H_anterior	R	F(s)	F+(s)	L_nuevo	H_nuevo	ancho
1	P	0.00000000 0000	1.00000000 0000	1.00000000 0000	0.73076923 0769	0.80769230 7692	0.73076923 0769	0.80769230 7692	0.07692307 6923
2	A	0.73076923 0769	0.80769230 7692	0.07692307 6923	0.00000000 0000	0.15384615 3846	0.73076923 0769	0.74260355 0296	0.01183431 9527
3	B	0.73076923 0769	0.74260355 0296	0.01183431 9527	0.15384615 3846	0.23076923 0769	0.73258989 5312	0.73350022 7583	0.00091033 2271

4	L	0.73258989 5312	0.73350022 7583	0.00091033 2271	0.38461538 4615	0.53846153 8462	0.73294002 3108	0.73308007 4227	0.00014005 1119
5	O	0.73294002 3108	0.73308007 4227	0.00014005 1119	0.57692307 6923	0.73076923 0769	0.73302082 1831	0.73304236 8157	0.00002154 6326
6	P	0.73302082 1831	0.73304236 8157	0.00002154 6326	0.73076923 0769	0.80769230 7692	0.73303656 7223	0.73303822 4632	0.00000165 7410
7	A	0.73303656 7223	0.73303822 4632	0.00000165 7410	0.00000000 0000	0.15384615 3846	0.73303656 7223	0.73303682 2209	0.00000025 4986
8	B	0.73303656 7223	0.73303682 2209	0.00000025 4986	0.15384615 3846	0.23076923 0769	0.73303660 6451	0.73303662 6066	0.00000001 9614
9	L	0.73303660 6451	0.73303662 6066	0.00000001 9614	0.38461538 4615	0.53846153 8462	0.73303661 3995	0.73303661 7013	0.00000000 3018
10	I	0.73303661 3995	0.73303661 7013	0.00000000 3018	0.30769230 7692	0.38461538 4615	0.73303661 4924	0.73303661 5156	0.00000000 0232
11	T	0.73303661 4924	0.73303661 5156	0.00000000 0232	0.80769230 7692	0.88461538 4615	0.73303661 5111	0.73303661 5129	0.00000000 0018
12	O	0.73303661 5111	0.73303661 5129	0.00000000 0018	0.57692307 6923	0.73076923 0769	0.73303661 5122	0.73303661 5124	0.00000000 0003
13	C	0.73303661 5122	0.73303661 5124	0.00000000 0003	0.23076923 0769	0.30769230 7692	0.73303661 5122	0.73303661 5122	0.00000000 0000
14	L	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.38461538 4615	0.53846153 8462	0.73303661 5122	0.73303661 5122	0.00000000 0000

15	A	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.00000000 0000	0.15384615 3846	0.73303661 5122	0.73303661 5122	0.00000000 0000
16	V	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.92307692 3077	1.00000000 0000	0.73303661 5122	0.73303661 5122	0.00000000 0000
17	O	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.57692307 6923	0.73076923 0769	0.73303661 5122	0.73303661 5122	0.00000000 0000
18	U	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.88461538 4615	0.92307692 3077	0.73303661 5122	0.73303661 5122	0.00000000 0000
19	N	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.53846153 8462	0.57692307 6923	0.73303661 5122	0.73303661 5122	0.00000000 0000
20	C	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.23076923 0769	0.30769230 7692	0.73303661 5122	0.73303661 5122	0.00000000 0000
21	L	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.38461538 4615	0.53846153 8462	0.73303661 5122	0.73303661 5122	0.00000000 0000
22	A	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.00000000 0000	0.15384615 3846	0.73303661 5122	0.73303661 5122	0.00000000 0000
23	V	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.92307692 3077	1.00000000 0000	0.73303661 5122	0.73303661 5122	0.00000000 0000
24	I	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.30769230 7692	0.38461538 4615	0.73303661 5122	0.73303661 5122	0.00000000 0000
25	T	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.80769230 7692	0.88461538 4615	0.73303661 5122	0.73303661 5122	0.00000000 0000

26	O	0.73303661 5122	0.73303661 5122	0.00000000 0000	0.57692307 6923	0.73076923 0769	0.73303661 5122	0.73303661 5122	0.00000000 0000
----	---	--------------------	--------------------	--------------------	--------------------	--------------------	--------------------	--------------------	--------------------

Para calcular la longitud en la codificación aritmética, primero debemos saber el valor medio de la cota inferior y superior, es decir: $\frac{L+H}{2}$

- Bits totales: 87 *bits*
 - Longitud Media: $L \approx 3,346 \text{ bits}$
 - Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 26 \times 8 = 208 \text{ bits}$
- $$\left(1 - \frac{87}{208}\right) \cdot 100\% = 58,17\%$$

Realizando el mismo proceso para el texto:

COMOQUIERESQUETEQUIERASIQUIENQUIEROQUEMEQUIERA

i	simb olo	L_anterior	H_anterior	R	F(s)	F+(s)	L_nuevo	H_nuevo	ancho
1	C	0.0000000 00000	1.0000000 00000	1.0000000 00000	0.0434782 60870	0.0652173 91304	0.0434782 60870	0.0652173 91304	0.0217391 30435
2	O	0.0434782 60870	0.0652173 91304	0.0217391 30435	0.4782608 69565	0.5434782 60870	0.0538752 36295	0.0552930 05671	0.0014177 69376
3	M	0.0538752 36295	0.0552930 05671	0.0014177 69376	0.4130434 78261	0.4565217 39130	0.0544608 36689	0.0545224 78836	0.0000616 42147
4	O	0.0544608 36689	0.0545224 78836	0.0000616 42147	0.4782608 69565	0.5434782 60870	0.0544903 17716	0.0544943 37856	0.0000040 20140
5	Q	0.0544903 17716	0.0544943 37856	0.0000040 20140	0.5434782 60870	0.6956521 73913	0.0544925 02575	0.0544931 14335	0.0000006 11760
6	U	0.0544925 02575	0.0544931 14335	0.0000006 11760	0.8478260 86957	1.0000000 00000	0.0544930 21241	0.0544931 14335	0.0000000 93094
7	I	0.0544930 21241	0.0544931 14335	0.0000000 93094	0.2826086 95652	0.4130434 78261	0.0544930 47550	0.0544930 59693	0.0000000 12143

8	E	0.0544930 47550	0.0544930 59693	0.0000000 12143	0.0652173 91304	0.2826086 95652	0.0544930 48342	0.0544930 50982	0.0000000 02640
9	R	0.0544930 48342	0.0544930 50982	0.0000000 02640	0.6956521 73913	0.7826086 95652	0.0544930 50179	0.0544930 50408	0.0000000 00230
10	E	0.0544930 50179	0.0544930 50408	0.0000000 00230	0.0652173 91304	0.2826086 95652	0.0544930 50194	0.0544930 50244	0.0000000 00050
11	S	0.0544930 50194	0.0544930 50244	0.0000000 00050	0.7826086 95652	0.8260869 56522	0.0544930 50233	0.0544930 50235	0.0000000 00002
12	Q	0.0544930 50233	0.0544930 50235	0.0000000 00002	0.5434782 60870	0.6956521 73913	0.0544930 50234	0.0544930 50234	0.0000000 00000
13	U	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.8478260 86957	1.0000000 00000	0.0544930 50234	0.0544930 50234	0.0000000 00000
14	E	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0652173 91304	0.2826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
15	T	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.8260869 56522	0.8478260 86957	0.0544930 50234	0.0544930 50234	0.0000000 00000
16	E	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0652173 91304	0.2826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
17	Q	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.5434782 60870	0.6956521 73913	0.0544930 50234	0.0544930 50234	0.0000000 00000
18	U	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.8478260 86957	1.0000000 00000	0.0544930 50234	0.0544930 50234	0.0000000 00000

19	I	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.2826086 95652	0.4130434 78261	0.0544930 50234	0.0544930 50234	0.0000000 00000
20	E	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0652173 91304	0.2826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
21	R	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.6956521 73913	0.7826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
22	A	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0000000 00000	0.0434782 60870	0.0544930 50234	0.0544930 50234	0.0000000 00000
23	S	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.7826086 95652	0.8260869 56522	0.0544930 50234	0.0544930 50234	0.0000000 00000
24	I	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.2826086 95652	0.4130434 78261	0.0544930 50234	0.0544930 50234	0.0000000 00000
25	Q	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.5434782 60870	0.6956521 73913	0.0544930 50234	0.0544930 50234	0.0000000 00000
26	U	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.8478260 86957	1.0000000 00000	0.0544930 50234	0.0544930 50234	0.0000000 00000
27	I	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.2826086 95652	0.4130434 78261	0.0544930 50234	0.0544930 50234	0.0000000 00000
28	E	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0652173 91304	0.2826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
29	N	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.4565217 39130	0.4782608 69565	0.0544930 50234	0.0544930 50234	0.0000000 00000

30	Q	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.5434782 60870	0.6956521 73913	0.0544930 50234	0.0544930 50234	0.0000000 00000
31	U	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.8478260 86957	1.0000000 00000	0.0544930 50234	0.0544930 50234	0.0000000 00000
32	I	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.2826086 95652	0.4130434 78261	0.0544930 50234	0.0544930 50234	0.0000000 00000
33	E	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0652173 91304	0.2826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
34	R	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.6956521 73913	0.7826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
35	O	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.4782608 69565	0.5434782 60870	0.0544930 50234	0.0544930 50234	0.0000000 00000
36	Q	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.5434782 60870	0.6956521 73913	0.0544930 50234	0.0544930 50234	0.0000000 00000
37	U	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.8478260 86957	1.0000000 00000	0.0544930 50234	0.0544930 50234	0.0000000 00000
38	E	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0652173 91304	0.2826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
39	M	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.4130434 78261	0.4565217 39130	0.0544930 50234	0.0544930 50234	0.0000000 00000
40	E	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0652173 91304	0.2826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000

4 1	Q	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.5434782 60870	0.6956521 73913	0.0544930 50234	0.0544930 50234	0.0000000 00000
4 2	U	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.8478260 86957	1.0000000 00000	0.0544930 50234	0.0544930 50234	0.0000000 00000
4 3	I	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.2826086 95652	0.4130434 78261	0.0544930 50234	0.0544930 50234	0.0000000 00000
4 4	E	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0652173 91304	0.2826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
4 5	R	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.6956521 73913	0.7826086 95652	0.0544930 50234	0.0544930 50234	0.0000000 00000
4 6	A	0.0544930 50234	0.0544930 50234	0.0000000 00000	0.0000000 00000	0.0434782 60870	0.0544930 50234	0.0544930 50234	0.0000000 00000

- Bits totales: 148 *bits*
- Longitud Media: $L \approx 3,217 \text{ bits}$
- Porcentaje de Compresión:
 - Texto original: 8 *bits* por símbolo $\rightarrow 46 \times 8 = 368 \text{ bits}$
$$\left(1 - \frac{149}{368}\right) \cdot 100\% = 59,78\%$$

b. Comparar los porcentajes obtenidos en cada uno de los métodos.

Texto	Estáticos			Dinámicos			
	Huffman	Shannon	Fano	LZ	LZW	Huffman Dinámico	Codificación Aritmética
PABLOPABLITO...	57,69%	54,8%	57,69%	22,11%	9,13%	34,1%	58,17%
COMOQUIERES...	59,51%	54,89%	59,51%	29,08%	16,85%	59,51%	59,78%

FUENTES DE MARKOV

1. Dada la secuencia (*alfabeto* $\{a, b, c, d\}$):

abacabadabacabaacbbadcab|ab

- a. Estimar las probabilidades condicionales de un proceso de Markov de primer orden y construir la matriz de transición.

Símbolo A

- 1° a → seguido por b
- 2° a → seguido por c
- 3° a → seguido por b
- 4° a → seguido por d
- 5° a → seguido por b
- 6° a → seguido por c
- 7° a → seguido por b
- 8° a → seguido por a
- 9° a → seguido por c
- 10° a → seguido por d
- 11° a → seguido por b
- 12° a → seguido por b

Transiciones

- a → a = 1 vez
- a → b = 6 veces
- a → c = 3 veces
- a → d = 2 veces

Símbolo B

- 1° b → seguido por a
- 2° b → seguido por a
- 3° b → seguido por a
- 4° b → seguido por a
- 5° b → seguido por b
- 6° b → seguido por a
- 7° b → seguido por a

Transiciones

- b → a = 6 veces
- b → b = 1 vez
- b → c = 0 veces
- b → d = 0 veces

Símbolo C

- 1° c → seguido por a
- 2° c → seguido por a
- 3° c → seguido por b
- 4° c → seguido por a

Transiciones

- c → a = 3 veces
- c → b = 1 vez
- c → c = 0 veces
- c → d = 0 veces

Símbolo D

1° $d \rightarrow$ seguido por a

2° $d \rightarrow$ seguido por c


Transiciones

- $d \rightarrow a = 1$ vez
- $d \rightarrow b = 0$ veces
- $d \rightarrow c = 0$ veces
- $d \rightarrow d = 1$ vez

Luego la matriz de transición es:

$$\begin{array}{c} \begin{matrix} & a & b & c & d \end{matrix} \\ \begin{matrix} a \\ b \\ c \\ d \end{matrix} \left[\begin{array}{cccc} 1/12 & 6/12 & 3/12 & 2/12 \\ 6/7 & 1/7 & 0 & 0 \\ 3/4 & 1/4 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 \end{array} \right] \end{array}$$

b. Dibujar el grafo de estado



2. A partir del ejercicio N°1

a. Obtener la matriz estacionaria (distribución a la que tiende).

Sea P la matriz de transición. La distribución estacionaria π es el vector fila que satisface:

$$\pi P = \pi, \quad \sum_i \pi_i = 1, \quad \pi_i \geq 0$$

Como el alfabeto es $\{a, b, c, d\}$ el vector es de cuatro componentes:

$$\pi = (\pi_a, \pi_b, \pi_c, \pi_d)$$

$$P = \begin{pmatrix} \frac{1}{12} & \frac{6}{12} & \frac{3}{12} & \frac{2}{12} \\ \frac{6}{7} & \frac{1}{7} & 0 & 0 \\ \frac{3}{4} & \frac{1}{4} & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \end{pmatrix}$$

Resolvemos el sistema de ecuaciones:

$$\pi P = \pi = \begin{cases} \pi_a = \frac{1}{12}\pi_a + \frac{6}{7}\pi_b + \frac{3}{4}\pi_c + \frac{1}{2}\pi_d & (1) \\ \pi_b = \frac{6}{12}\pi_a + \frac{1}{7}\pi_b + \frac{1}{4}\pi_c & (2) \\ \pi_c = \frac{3}{12}\pi_a + \frac{1}{2}\pi_d & (3) \\ \pi_d = \frac{2}{12}\pi_a & (4) \end{cases}$$

Reemplazamos con (4) en (3):

$$\pi_c = \frac{3}{12}\pi_a + \frac{1}{2}\left(\frac{2}{12}\pi_a\right)$$

$$\pi_c = \frac{3}{12}\pi_a + \frac{1}{12}\pi_a$$

$$\pi_c = \frac{1}{3}\pi_a \quad (5)$$

Reemplazamos con (5) en (2):

$$\begin{aligned}\pi_b &= \frac{6}{12}\pi_a + \frac{1}{7}\pi_b + \frac{1}{4}\left(\frac{1}{3}\pi_a\right) \\ \pi_b &= \frac{6}{12}\pi_a + \frac{1}{12}\pi_a + \frac{1}{7}\pi_b \\ \pi_b - \frac{1}{7}\pi_b &= \frac{7}{12}\pi_a \\ \pi_b &= \frac{7}{12}\pi_a \cdot \frac{6}{7} \\ \pi_b &= \frac{49}{72}\pi_a \quad (6)\end{aligned}$$

Reemplazamos con (4), (5), y (6) en (1):

$$\begin{aligned}\pi_a &= \frac{1}{12}\pi_a + \frac{6}{7}\left(\frac{49}{72}\pi_a\right) + \frac{3}{4}\left(\frac{1}{3}\pi_a\right) + \frac{1}{2}\left(\frac{2}{12}\pi_a\right) \\ \pi_a &= 1 \cdot \pi_a \\ \pi_a &= \pi_a\end{aligned}$$

Como $\sum_i \pi_i = 1$, eso quiere decir que $\pi_a + \pi_b + \pi_c + \pi_d = 1$.

$$\begin{aligned}\pi_b &= \frac{49}{72}\pi_a; \quad \pi_c = \frac{1}{3}\pi_a; \quad \pi_d = \frac{2}{12}\pi_a \\ \pi_a + \pi_b + \pi_c + \pi_d &= \pi_a + \frac{49}{72}\pi_a + \frac{1}{3}\pi_a + \frac{2}{12}\pi_a = \pi_a \left(1 + \frac{49}{72} + \frac{1}{3} + \frac{2}{12}\right) = \pi_a \cdot \frac{157}{72} = 1 \rightarrow \pi_a = \frac{72}{157}\end{aligned}$$

Luego:

$$\pi_a = \frac{72}{157}; \quad \pi_b = \frac{49}{157}; \quad \pi_c = \frac{24}{157}; \quad \pi_d = \frac{12}{157}$$

Finalmente:

$$\pi = \left(\frac{72}{157}, \frac{49}{157}, \frac{24}{157}, \frac{12}{157}\right) \approx (0.4586, 0.3121, 0.1529, 0.0764)$$

- b. Comprobar que las potencias sucesivas de la matriz de transición tienen menor variabilidad en los valores de sus componentes.

Mido la “variabilidad” como la desviación estándar entre filas por columna (poblacional), y promedio esas cuatro desviaciones.

Para cada potencia n y cada columna j , tomo los 4 números $\{(P^n)_{aj}, (P^n)_{bj}, (P^n)_{cj}, (P^n)_{dj}\}$ y calculo:

- Media de columna:

$$\bar{p}_j^n = \frac{1}{4} \sum_{i \in \{a,b,c,d\}} (P^n)_{ij}$$

- Desviación estándar (poblacional) entre filas de esa columna:

$$\sigma_j^n = \sqrt{\frac{1}{4} \sum_i ((P^n)_{ij} - \bar{p}_j^n)^2}$$

- Promedio de las 4 σ :

$$\bar{\sigma}^n = \frac{1}{4} \sum_{j \in \{a,b,c,d\}} \sigma_j^n$$

Luego:

Potencia	$\sigma(\text{columna a})$	$\sigma(\text{columna b})$	$\sigma(\text{columna c})$	$\sigma(\text{columna d})$	Promedio σ
(P^1)	0.297738	0.182763	0.207289	0.072169	0.189990
(P^2)	0.194799	0.105474	0.044791	0.049623	0.098672
(P^3)	0.128617	0.072232	0.023939	0.032466	0.064314
(P^5)	0.056697	0.031845	0.010624	0.014228	0.028349
(P^{10})	0.007323	0.004112	0.001373	0.001838	0.003662

La dispersión entre filas disminuye sistemáticamente. Esto muestra que las filas de P^n se van igualando y convergen a la misma distribución límite π , es decir, hay menor variabilidad en los componentes a medida que crece n .

- c. Comprobar que la distribución estacionaria es la misma para el cuadrado de la matriz de transición. Si π es estacionaria para P , o sea $\pi P = \pi$, entonces:

$$\pi P^2 = (\pi P)P = \pi P = \pi$$

Por inducción, también $\pi P^k = \pi$ para cualquier $k \in \mathbb{N}$.

- d. ¿Es un proceso ergódico?

En cadenas de Markov finitas, si existe una potencia n tal que P^n tiene todas sus entradas estrictamente positivas (> 0), la cadena es primitiva $\Rightarrow$ irreducible y aperiódica $\Rightarrow$ ergódica (con distribución estacionaria única y $P^n \rightarrow 1\pi$).

$$P^2 = \begin{pmatrix} \frac{89}{126} & \frac{59}{336} & \frac{5}{48} & \frac{1}{72} \\ \frac{19}{98} & \frac{22}{49} & \frac{3}{14} & \frac{1}{7} \\ \frac{31}{112} & \frac{23}{56} & \frac{3}{16} & \frac{1}{8} \\ \frac{5}{12} & \frac{3}{8} & \frac{1}{8} & \frac{1}{12} \end{pmatrix}$$

Todas las 16 entradas son positivas.

- Como $P^2 > 0$ la cadena es positiva.
- Por lo tanto es irreducible (hay camino entre cualesquiera dos estados) y aperiódica (P^2 tiene diagonal positiva, que rompe periodicidad).
- En consecuencia, la cadena es ergódica:
 - Existe una única distribución estacionaria.
 - $P^n \rightarrow 1\pi$ cuando $n \rightarrow \infty$

3. Comprobar que las filas de la matriz de transición son linealmente dependientes en un proceso de Markov. La afirmación es falsa en general. Las filas de una matriz de transición P (estocástica por filas) no tienen por qué ser linealmente dependientes.

Por ejemplo: $P = I_n$ (la identidad) es estocástica y sus n filas (las bases canónicas) son linealmente independientes.

Lo que si es cierto es que las filas de $(I - P)$ siempre son linealmente dependientes.

Como P es estocástica por filas, $\sum_j p_{ij} = 1$ para cada i .

Entonces, para cada fila i de $(I - P)$:

$$\sum_j (I - P)_{ij} = \sum_j (\delta_{ij} - p_{ij}) = 1 - \sum_j p_{ij} = 1 - 1 = 0$$

Como en P cada fila suma 1, en $(I - P)$ cada fila suma 0; eso fuerza que $(I - P)$ “pierda” una dimensión (no tiene rango completo), y por lo tanto **sus filas no pueden ser todas independientes**.

Siendo:

$$I_4 = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad P = \begin{pmatrix} \frac{1}{12} & \frac{6}{12} & \frac{3}{12} & \frac{2}{12} \\ \frac{6}{7} & \frac{1}{7} & 0 & 0 \\ \frac{3}{4} & \frac{1}{4} & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \end{pmatrix}$$

Si comprobamos la dependencia de las filas de $(I - P)$ con la primer fila de P , entonces:

$$\sum_j (I - P)_{1j} = 1 - \sum_j p_{1j} = 1 - \left(\frac{1}{12} + \frac{6}{12} + \frac{3}{12} + \frac{2}{12} \right) = 1 - 1 = 0$$

4. Dado el siguiente ejemplo decir:
 - a. ¿De qué orden es el sistema de Markov?
 - b. Sea $S = (s_1, s_2, s_3, s_4)$ $p(s_i/s_{j1}, s_{j2}, s_{j3})$
 - c. ¿En cuántos estados puede encontrarse el sistema?
 - d. Supuestas conocidas todas las probabilidades condicionales ¿cuál será la forma del sistema de ecuaciones para encontrar las $p(s_i)$?
5. Supongamos una máquina con dos estados, *anda* = 1, *no anda* = 2. Estudiamos el proceso día a día llegando a comprobar que:
 - i. Si anda hoy, hay un 75% de chances que ande mañana.
 - ii. Si no anda hoy la arreglan mañana.
 - a. Encontrar la matriz de transición
 - b. Calcular hasta la quinta potencia de la matriz de transición y analizar los resultados
 - c. Encontrar la matriz de equilibrio o estacionaria

6. Dado un proceso de Markov con tres estados a, b, c ; con las siguientes probabilidades:

$$p(a/a) = 3/4$$

$$p(c/c) = p(b/b) = 1/2$$

$$p(b/a) = p(c/a) = 1/8$$

$$p(a/b) = p(c/b) = p(a/c) = p(b/c) = 1/4$$

Comprobar que la longitud de Markov para un código compacto $LM = 11/8 < 12/8 = L$

7. Usando el texto del ejercicio 5, Práctico No 3

- a. Codificar mediante los métodos: Huffman, Fano y Shannon como fuente de Markov de orden 1.

PABLOPABLITOC LAVOUNCLAVIT|O

- Símbolo P
 - $P \rightarrow A = 2$
- Símbolo A
 - $A \rightarrow B = 2$
 - $A \rightarrow V = 2$
- Símbolo B
 - $B \rightarrow L = 2$
- Símbolo L
 - $L \rightarrow O = 1$
 - $L \rightarrow A = 2$
 - $L \rightarrow I = 1$
- Símbolo O
 - $O \rightarrow P = 1$
 - $O \rightarrow C = 1$
 - $O \rightarrow U = 1$
- Símbolo I
 - $I \rightarrow T = 2$
- Símbolo T
 - $T \rightarrow O = 2$
- Símbolo C
 - $C \rightarrow L = 2$
- Símbolo V
 - $V \rightarrow O = 1$
 - $V \rightarrow I = 1$
- Símbolo U
 - $U \rightarrow N = 1$
- Símbolo N
 - $N \rightarrow C = 1$

P A B L O C V U N I T

P	0	1	0	0	0	0	0	0	0	0	0
A	0	0	$1/2$	0	0	0	$1/2$	0	0	0	0
B	0	0	0	1	0	0	0	0	0	0	0
L	0	$1/2$	0	0	$1/4$	0	0	0	0	$1/4$	0
O	$1/3$	0	0	0	0	$1/3$	0	$1/3$	0	0	0
C	0	0	0	1	0	0	0	0	0	0	0
V	0	0	0	0	$1/2$	0	0	0	0	$1/2$	0
U	0	0	0	0	0	0	0	0	1	0	0
N	0	0	0	0	0	1	0	0	0	0	0
I	0	0	0	0	0	0	0	0	0	0	1
T	0	0	0	0	1	0	0	0	0	0	0


Huffman

Se construye un código por contexto (símbolo previo), pero solo se necesita construir un árbol cuando en ese contexto hay más de una salida posible.

Con la matriz, los contextos con > 1 transición son 4: A, L, O y V.


- A: $\{B: 1/2, V: 1/2\} \rightarrow B = 0, V = 1$

Contexto A




- L: $\{A: 1/2, O: 1/4, I: 1/4\} \rightarrow A = 0, O = 10, I = 11$

Contexto L




- O: $\{P: 1/3, C: 1/3, U: 1/3\} \rightarrow P = 00, C = 01, U = 10$

Contexto O



- V: $\{O: 1/2, I: 1/2\} \rightarrow O = 0, I = 1$

Contexto V



- Contextos deterministas (no emiten bits, ϵ):
 - $P \rightarrow A$
 - $B \rightarrow L$

- $C \rightarrow L$
- $U \rightarrow N$
- $N \rightarrow C$
- $I \rightarrow T$
- $T \rightarrow O$

Codificación paso a paso del texto:

1. $P \rightarrow A: \varepsilon$
2. $A \rightarrow B: 0$
3. $B \rightarrow L: \varepsilon$
4. $L \rightarrow O: 10$
5. $O \rightarrow P: 00$
6. $P \rightarrow A: \varepsilon$
7. $A \rightarrow B: 0$
8. $B \rightarrow L: \varepsilon$
9. $L \rightarrow I: 11$
10. $I \rightarrow T: \varepsilon$
11. $T \rightarrow O: \varepsilon$
12. $O \rightarrow C: 01$
13. $C \rightarrow L: \varepsilon$
14. $L \rightarrow A: 0$
15. $A \rightarrow V: 1$
16. $V \rightarrow O: 0$
17. $O \rightarrow U: 10$
18. $U \rightarrow N: \varepsilon$
19. $N \rightarrow C: \varepsilon$
20. $C \rightarrow L: \varepsilon$
21. $L \rightarrow A: 0$
22. $A \rightarrow V: 1$
23. $V \rightarrow I: 1$
24. $I \rightarrow T: \varepsilon$
25. $T \rightarrow O: \varepsilon$

Bitstream final: 010000110101010011

Bits totales: 18

Transiciones codificadas: 25 (todas menos la primera letra)

Longitud media: $L_H = \frac{18}{25} = 0,72 \text{ bits/símbolo}$

$$H(X|Y) = \frac{4}{25} \cdot 1 + \frac{4}{25} \cdot 1.5 + \frac{3}{25} \cdot \log_2 3 + \frac{2}{25} \cdot 1 = \frac{4}{25} + \frac{6}{25} + \frac{3 \log_2 3}{25} + \frac{2}{25}$$

$$H(X|Y) = \frac{16.7548875}{25} \approx 0,6702 \text{ bits/símbolo}$$

Se cumple la cota de Huffman por contexto:

$$H(X|Y) \leq L < H(X|Y) + 1 \Rightarrow 0,6702 \leq 0,72 < 1,6702$$

Shannon

Para cada contexto, ordenamos los símbolos por $p(x|y)$, fijamos las longitudes $l_x = \lceil -\log_2 p(x|y) \rceil$, y asignamos los códigos usando las probabilidades acumuladas. Solo hay 4 contextos con > 1 salida: A, L, O, V.

- A: {B: $\frac{1}{2}$, V: $\frac{1}{2}$ }
 - $l_B = -\log_2 \left(\frac{1}{2}\right) = 1 \rightarrow B = 0$
 - $l_V = -\log_2 \left(\frac{1}{2}\right) = 1 \rightarrow V = 1$
- L: {A: $\frac{1}{2}$, O: $\frac{1}{4}$, I: $\frac{1}{4}$ }
 - $l_A = -\log_2 \left(\frac{1}{2}\right) = 1 \rightarrow A = 0$
 - $l_O = -\log_2 \left(\frac{1}{4}\right) = 2 \rightarrow O = 10$
 - $l_I = -\log_2 \left(\frac{1}{4}\right) = 2 \rightarrow I = 11$
- O: {P: $\frac{1}{3}$, C: $\frac{1}{3}$, U: $\frac{1}{3}$ } $\rightarrow P = 00, C = 01, U = 10$
 - $l_P = -\log_2 \left(\frac{1}{3}\right) = 1,6 \approx 2 \rightarrow P = 00$
 - $l_C = -\log_2 \left(\frac{1}{3}\right) = 1,6 \approx 2 \rightarrow C = 01$
 - $l_U = -\log_2 \left(\frac{1}{3}\right) = 1,6 \approx 2 \rightarrow U = 10$
- V: {O: $\frac{1}{2}$, I: $\frac{1}{2}$ } $\rightarrow O = 0, I = 1$
 - $l_O = -\log_2 \left(\frac{1}{2}\right) = 1 \rightarrow O = 0$
 - $l_I = -\log_2 \left(\frac{1}{2}\right) = 1 \rightarrow I = 1$

Codificación paso a paso:

1. $P \rightarrow A: \varepsilon$
2. $A \rightarrow B: 0$
3. $B \rightarrow L: \varepsilon$
4. $L \rightarrow O: 10$
5. $O \rightarrow P: 00$
6. $P \rightarrow A: \varepsilon$
7. $A \rightarrow B: 0$
8. $B \rightarrow L: \varepsilon$
9. $L \rightarrow I: 11$
10. $I \rightarrow T: \varepsilon$
11. $T \rightarrow O: \varepsilon$
12. $O \rightarrow C: 01$
13. $C \rightarrow L: \varepsilon$
14. $L \rightarrow A: 0$
15. $A \rightarrow V: 1$
16. $V \rightarrow O: 0$
17. $O \rightarrow U: 10$
18. $U \rightarrow N: \varepsilon$
19. $N \rightarrow C: \varepsilon$
20. $C \rightarrow L: \varepsilon$
21. $L \rightarrow A: 0$
22. $A \rightarrow V: 1$
23. $V \rightarrow I: 1$
24. $I \rightarrow T: \varepsilon$
25. $T \rightarrow O: \varepsilon$

Bitstream final: 010000110101010011

Bits totales: 18

Transiciones codificadas: 25

Longitud media: $L_S = \frac{18}{25} = 0,72 \text{ bits/símbolo}$

Fano

En cada contexto, ordenamos por $p(x|y)$ y particionamos el conjunto en dos con suma de probabilidades lo más cercana a $\frac{1}{2}$, asignamos los códigos y repetimos recursivamente.

- A: {B: $\frac{1}{2}$ } | {V: $\frac{1}{2}$ } $\rightarrow B = 0, V = 1$
- L: {A: $\frac{1}{2}$ } | {O: $\frac{1}{4}, I: \frac{1}{4}$ } $\rightarrow A = 0, \{O: \frac{1}{4}\} | \{I: \frac{1}{4}\} \rightarrow O = 10, I = 11$
- O: {P: $\frac{1}{3}$ } | {C: $\frac{1}{3}, U: \frac{1}{3}$ } $\rightarrow P = 0, \{C: \frac{1}{3}\} | \{U: \frac{1}{3}\} \rightarrow C = 10, U = 11$
- V: {O: $\frac{1}{2}$ } | {I: $\frac{1}{2}$ } $\rightarrow O = 0, I = 1$

Codificación paso a paso:

1. P $\rightarrow$ A: ϵ
2. A $\rightarrow$ B: 0
3. B $\rightarrow$ L: ϵ
4. L $\rightarrow$ O: 10
5. O $\rightarrow$ P: 0
6. P $\rightarrow$ A: ϵ
7. A $\rightarrow$ B: 0
8. B $\rightarrow$ L: ϵ
9. L $\rightarrow$ I: 11
10. I $\rightarrow$ T: ϵ
11. T $\rightarrow$ O: ϵ
12. O $\rightarrow$ C: 10
13. C $\rightarrow$ L: ϵ
14. L $\rightarrow$ A: 0
15. A $\rightarrow$ V: 1
16. V $\rightarrow$ O: 0
17. O $\rightarrow$ U: 11
18. U $\rightarrow$ N: ϵ
19. N $\rightarrow$ C: ϵ
20. C $\rightarrow$ L: ϵ
21. L $\rightarrow$ A: 0
22. A $\rightarrow$ V: 1
23. V $\rightarrow$ I: 1
24. I $\rightarrow$ T: ϵ
25. T $\rightarrow$ O: ϵ

Bitstream final: 01000111001011011

Bits totales: 17

Transiciones codificadas: 25

Longitud media: $L_F = 17/25 = 0,68 \text{ bits/símbolo}$

- b. Relevar para la fuente la estadística de primer orden y realizar una codificación predictiva.

PABLOPABLITOCLAVOUNCLAVITO

Frecuencia de símbolos sin contexto y probabilidad de ocurrencia:

- P: 2 $\rightarrow p(P) = \frac{2}{26} = \frac{1}{13}$
- A: 4 $\rightarrow p(A) = \frac{4}{26} = \frac{2}{13}$
- B: 2 $\rightarrow p(B) = \frac{2}{26} = \frac{1}{13}$
- L: 4 $\rightarrow p(L) = \frac{4}{26} = \frac{2}{13}$
- O: 4 $\rightarrow p(O) = \frac{4}{26} = \frac{2}{13}$
- I: 2 $\rightarrow p(I) = \frac{2}{26} = \frac{1}{13}$
- T: 2 $\rightarrow p(T) = \frac{2}{26} = \frac{1}{13}$

- C: $2 \rightarrow p(C) = \frac{2}{26} = \frac{1}{13}$
- V: $2 \rightarrow p(V) = \frac{2}{26} = \frac{1}{13}$
- U: $1 \rightarrow p(U) = \frac{1}{26}$
- N: $1 \rightarrow p(N) = \frac{1}{26}$

Luego, la entropía de 1er orden:

$$H(X) = - \sum_x p(x) * \log_2(x)$$

$$H(X) = - \left(\left(\frac{1}{13} * \log_2 \left(\frac{1}{13} \right) \right) + \left(\frac{2}{13} * \log_2 \left(\frac{2}{13} \right) \right) + \left(\frac{1}{13} * \log_2 \left(\frac{1}{13} \right) \right) + \left(\frac{2}{13} * \log_2 \left(\frac{2}{13} \right) \right) \right. \\ \left. + \left(\frac{2}{13} * \log_2 \left(\frac{2}{13} \right) \right) + \left(\frac{1}{13} * \log_2 \left(\frac{1}{13} \right) \right) + \left(\frac{1}{13} * \log_2 \left(\frac{1}{13} \right) \right) + \left(\frac{1}{13} * \log_2 \left(\frac{1}{13} \right) \right) \right. \\ \left. + \left(\frac{1}{13} * \log_2 \left(\frac{1}{13} \right) \right) + \left(\frac{1}{26} * \log_2 \left(\frac{1}{26} \right) \right) + \left(\frac{1}{13} * \log_2 \left(\frac{1}{26} \right) \right) \right) = 3,3158 \frac{bits}{símbolo}$$

Elegimos el predictor por contexto $\hat{x}(y) = \arg \max_x p(x|y)$:

- Deterministas:

$$P \rightarrow A, B \rightarrow L, C \rightarrow L, U \rightarrow N, N \rightarrow C, I \rightarrow T, T \rightarrow O$$

- Con varias salidas (desempate alfabético):

$$A: \{B, V\} \rightarrow \hat{x}(A) = B$$

$$L: \left\{ A: \frac{1}{2}, O: \frac{1}{4}, I: \frac{1}{4} \right\} \rightarrow \hat{x}(L) = A$$

$$O: \{P, C, U\} \rightarrow \hat{x}(O) = C$$

$$V: \{O, I\} \rightarrow \hat{x}(V) = I$$

En contextos **no deterministas** (A, L, O, V): emitir 1 bit-flag por transición:

- 0 si $x = \hat{x}(y)$ (acierto).
- 1 si $x \neq \hat{x}(y)$ (fallo) y luego codificar el residuo.

En contextos **deterministas**: no emitir nada (ni flag ni residuo).

Códigos del residuo por contexto:

- A: no predichos = $\{V\} \rightarrow 0 \text{ bits}$
- L: no predichos = $\{O, I\} \rightarrow 1 \text{ bit } (O = 0, I = 1)$
- O: no predichos = $\{P, U\} \rightarrow 1 \text{ bit } (P = 0, U = 1)$
- V: no predichos = $\{O\} \rightarrow 0 \text{ bits}$

Recorrido del texto:

$$P \rightarrow A, A \rightarrow B, B \rightarrow L, L \rightarrow O, O \rightarrow P, P \rightarrow A, A \rightarrow B, B \rightarrow L, L \rightarrow I, I \rightarrow T, T \rightarrow O, O \rightarrow C, C \rightarrow L, L \\ \rightarrow A, A \rightarrow V, V \rightarrow O, O \rightarrow U, U \rightarrow N, N \rightarrow C, C \rightarrow L, L \rightarrow A, A \rightarrow V, V \rightarrow I, I \rightarrow T, T \\ \rightarrow O.$$

Resultados:

- Aciertos totales: 18
- Fallos totales: 7
 - En A: 2 fallos (siempre V) $\rightarrow$ residuo 0 bits cada uno
 - En L: 2 fallos (O e I) $\rightarrow$ 2 bits (1 por fallo)
 - En O: 2 fallos (P y U) $\rightarrow$ 2 bits (1 por fallo)
 - En V: 1 fallo (O) $\rightarrow$ residuo 0 bits

Costo en bits:

- Flags en contextos no deterministas: ocurrencias $A(4) + L(4) + O(3) + V(2) = 13 \text{ bits}$
- Residuos: 2 (en L) + 2 (en O) = 4 bits
- Deterministas: 0 bits

Total: $13 + 4 = 17 \text{ bits}$ para 25 transiciones

Longitud media: $\bar{L} = \frac{17}{25} = 0.68 \text{ bits/símbolo}$

c. Realizar una transformación Burrows-Wheeler y codificar mediante cuenta de símbolos iguales.

PASO 1: Crear todas las rotaciones cíclicas.

N°	ROTACIÓN																									
0	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O
1	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P
2	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A
3	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B
4	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L
5	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O
6	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P
7	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A
8	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B
9	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L
10	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I
11	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T
12	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O
13	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C
14	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L
15	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A
16	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V
17	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O
18	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U
19	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N
20	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C
21	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L
22	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A
23	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V
24	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I
25	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T

PASO 2: Ordenar las rotaciones lexicográficamente.

N°	ROTACIÓN																									
1	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P
6	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P
14	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L
21	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L
2	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A
7	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A
12	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O
19	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N
9	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L
23	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V
3	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B
8	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B
13	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C
20	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C
18	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U
4	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L

11	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T
16	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V
25	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T
0	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O
5	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O
10	T	O	C	L	A	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I
24	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A	V	I
17	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O
15	V	O	U	N	C	L	A	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A
22	V	I	T	O	P	A	B	L	O	P	A	B	L	I	T	O	C	L	A	V	O	U	N	C	L	A

PASO 3: Extraer la última columna.

Último carácter
→ <i>P</i>
→ <i>P</i>
→ <i>L</i>
→ <i>L</i>
→ <i>A</i>
→ <i>A</i>
→ <i>O</i>
→ <i>N</i>
→ <i>L</i>
→ <i>V</i>
→ <i>B</i>
→ <i>B</i>
→ <i>C</i>
→ <i>C</i>
→ <i>U</i>
→ <i>L</i>
→ <i>T</i>
→ <i>V</i>
→ <i>T</i>
→ <i>O</i>
→ <i>O</i>
→ <i>I</i>
→ <i>I</i>
→ <i>O</i>
→ <i>A</i>
→ <i>A</i>

Resultado Final:

Si leemos la última columna de arriba abajo, obtenemos la transformada:

PPLAAONLVBCCULTVTTOOIIIOAA

Entrada: **PABLOPABLITOCLAVOUNCLAVITO**

Salida BWT: **PPLAAONLVBCCULTVTTOOIIIOAA**

Codificación mediante cuenta de símbolos iguales o RLE (run-length encoding)

Par(símbolo, cantidad de repeticiones)

(*P*, 2); (*L*, 2); (*A*, 2); (*O*, 1); (*N*, 1); (*L*, 1); (*V*, 1); (*B*, 2); (*C*, 2); (*U*, 1);

(*L*, 1); (*T*, 1); (*V*, 1); (*T*, 1); (*O*, 2); (*I*, 2); (*O*, 1); (*A*, 2)

Son 18 *runs* y la suma de conteos es 26

Formato de RLE:

- Conteo: como los conteos máximos son ≤ 26 , $\lceil \log_2 26 \rceil \cong 5$, con 5 *bits* alcanza.
- Alfabeto real: $\{P, A, B, L, O, I, T, C, V, U, N\} \rightarrow 11$ *símbolos*
- Símbolo con índice fijo de alfabeto: 4 *bits* ($\lceil \log_2 11 \rceil \cong 4$)
- Costo por run = 9 *bits*
- Además, la BWT necesita el índice primario: $\lceil \log_2 26 \rceil \cong 5$ *bits*

Calculo de bits totales:

- Texto original: 8 *bits* por símbolo $\rightarrow 26 \times 8 = 208$ *bits*
- RLE: 18 *runs* $\times 9$ *bits* = 162 *bits*
 - Índice BWT: 5
- Total: 167 *bits* $\rightarrow CR = \frac{167}{208} = 0,803 \rightarrow 19,71\%$ de compresión.

d. Obtener los porcentajes de compresión y comparar los resultados obtenidos.

Métricas:

- Ratio de compresión (CR):

$$CR = \frac{\text{tamaño comprimido}}{\text{tamaño original}}$$

- Porcentaje de compresión (reducción):

$$\%compresión = (1 - CR) \times 100\%$$

- Bits/símbolo:

$$\bar{L} = \frac{\text{bits totales}}{\text{nº de símbolos codificados}}$$

Método de Compresión	Bits totales	$\bar{L}(\text{bits/símbolo})$	$CR = \text{bits comprimidos}/208$	% compresión
Huffman (orden 1)	18	$\bar{L} = \frac{18}{25} = 0,72$	$CR = \frac{18}{208} = 0,08654$	91,35%
Shannon (orden 1)	18	$\bar{L} = \frac{18}{25} = 0,72$	$CR = \frac{18}{208} = 0,08654$	91,35%
Fano (orden 1)	17	$\bar{L} = \frac{17}{25} = 0,68$	$CR = \frac{17}{208} = 0,08173$	91,83%
Predictiva (orden 1)	17	$\bar{L} = \frac{17}{25} = 0,68$	$CR = \frac{17}{208} = 0,08173$	91,83%
BWT + RLE	167	$\bar{L} = \frac{167}{26} = 6,423$	$CR = \frac{167}{208} = 0,80288$	19,71%

PRÁCTICO N°4

1. Comprobar para los siguientes conjuntos de probabilidades que $H_r \leq l$.

a. $p_1 = 0,4; p_2 = 0,2; p_3 = 0,2; p_4 = 0,1; p_5 = 0,1$

- $H = -\sum p_i \log_2(p_i)$

$$H_1 = -[0,4 \cdot \log_2(0,4) + 0,2 \cdot \log_2(0,2) + 0,2 \cdot \log_2(0,2) + 0,1 \cdot \log_2(0,1) + 0,1 \cdot \log_2(0,1)]$$

$$H_1 = -[0,4 \cdot (-1,322) + 2 \cdot 0,2 \cdot (-2,322) + 2 \cdot 0,1 \cdot (-3,322)]$$

$$H_1 = -[-0,529 - 0,929 - 0,664]$$

$$H_1 = 2,122 \text{ bits}$$

- $H_r = \left(\frac{1}{1-r}\right) \log_2(\sum p_i^r)$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2 \left(\sum p_i^{0,5}\right)$$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2(\sqrt{0,4} + \sqrt{0,2} + \sqrt{0,2} + \sqrt{0,1} + \sqrt{0,1})$$

$$H_{0,5} = (1/(1-0,5)) \log_2(0,632 + 0,447 + 0,447 + 0,316 + 0,316)$$

$$H_{0,5} = (1/(1-0,5)) \log_2(2,158)$$

$$H_{0,5} = 2 \times 1,110 = 2,220 \text{ bits}$$

Conclusión: Se cumple la desigualdad " $H_r \leq l$ ".

b. $p_1 = 0,4; p_2 = 0,4; p_3 = 0,1; p_4 = 0,1$

- $H = -\sum p_i \log_2(p_i)$

$$H_1 = -[2 \cdot 0,4 \cdot \log_2(0,4) + 2 \cdot 0,1 \cdot \log_2(0,1)]$$

$$H_1 = -[0,8 \cdot (-1,322) + 0,2 \cdot (-3,322)]$$

$$H_1 = 1,722 \text{ bits}$$

- $H_r = \left(\frac{1}{1-r}\right) \log_2(\sum p_i^r)$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2 \left(\sum p_i^{0,5}\right)$$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2(2\sqrt{0,4} + 2\sqrt{0,1})$$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2(1,265 + 0,632)$$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2(1,897)$$

$$H_{0,5} = 2 \times 0,924 = 2,220 \text{ bits}$$

Conclusión: Se cumple la desigualdad " $H_r \leq l$ ".

c. $p_1 = 0,4; p_2 = 0,3; p_3 = 0,2; p_4 = 0,1$

- $H = -\sum p_i \log_2(p_i)$

$$H_1 = -[0,4 \cdot \log_2(0,4) + 0,3 \cdot \log_2(0,3) + 0,2 \cdot \log_2(0,2) + 0,1 \cdot \log_2(0,1)]$$

$$H_1 = -[0,4 \cdot (-1,322) + 0,3 \cdot (-1,737) + 0,2 \cdot (-2,322) + 0,1 \cdot (-3,322)]$$

$$H_1 = 1,846 \text{ bits}$$

- $H_r = \left(\frac{1}{1-r}\right) \log_2(\sum p_i^r)$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2 \left(\sum p_i^{0,5}\right)$$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2(\sqrt{0,4} + \sqrt{0,3} + \sqrt{0,2} + \sqrt{0,1})$$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2(0,632 + 0,548 + 0,447 + 0,316)$$

$$H_{0,5} = \left(\frac{1}{1-0,5}\right) \log_2(1,943)$$

$$H_{0,5} = 2 \times 0,9581,916 \text{ bits}$$

Conclusión: Se cumple la desigualdad " $H_r \leq l$ ".

2. Sea una fuente S con eventos s_1, s_2, s_3, s_4 de $p(s_i) = \frac{1}{4}$ ¿es posible encontrar un $L = 1,86$ para cada codificación? ¿Cuál es el mínimo valor que en ese caso puede tomar L?

$$H = - \sum \left(\frac{1}{4}\right) \log_2 \left(\frac{1}{4}\right)$$

$$H = -4 \times \left(\frac{1}{4}\right) \times \log_2 \left(\frac{1}{4}\right)$$

$$H = -4 \times \left(\frac{1}{4}\right) \times (-2) = 2 \text{ bits}$$

No es posible encontrar un $L=1,86$ para cada codificación, dado que $H \leq L$. siendo $H = 2$ y $L = 1.86$.

Para saber cuál es el mínimo valor que en ese caso puede tomar L debemos:

Construimos un código de longitud fija $l_i = 2$ para los 4 símbolos:

Código binario:

- $s_1 \rightarrow 00$
- $s_2 \rightarrow 01$
- $s_3 \rightarrow 10$
- $s_4 \rightarrow 11$

Longitud media: $\sum_i p_i l_i = 4 \times \left(\frac{1}{4}\right) \times 2 = 2 \text{ bits/símbolo}$

No es posible bajar de $L=2$.

Si intentamos usar alguna palabra de longitud 1 para "bajar" el promedio:

- Capacidad usada: $2^{-1} = \frac{1}{2}$
- Capacidad restante: $1 - \frac{1}{2} = \frac{1}{2}$ para los otros 3 símbolos.

La combinación que minimiza longitudes es $l = (1,2,3,3)$:

Verificación de Kraft:

$$\sum 2^{-l_i} = 2^{-1} + 2^{-2} + 2^{-3} + 2^{-3} = \frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{8} = 1$$

Longitud media:

$$\bar{L} = \left(\frac{1}{4}\right) (1 + 2 + 3 + 3) = \left(\frac{1}{4}\right) (9) = 2.25 > 2$$

$L = (2,2,2,2)$ es el mínimo factible.

3. Repetir el ejemplo anterior pero con $p(s_1) = \frac{1}{2}$; $p(s_2) = \frac{1}{4}$; $p(s_3) = p(s_4) = \frac{1}{8}$

$$H = - \sum p_i \log_2(p_i)$$

$$H = - \left(\frac{1}{2} \cdot \log_2 \left(\frac{1}{2} \right) + \frac{1}{4} \cdot \log_2 \left(\frac{1}{4} \right) + 2 \cdot \frac{1}{8} \cdot \log_2 \left(\frac{1}{8} \right) \right)$$

$$H = - \left(\frac{1}{2} \cdot (-1) + \frac{1}{4} \cdot (-2) + 2 \cdot \frac{1}{8} \cdot (-3) \right)$$

$$H = -((-0.5) + (-0.5) + (-0.75))$$

$$H = 0.5 + 0.5 + 0.75 = 1.75 \text{ bits}$$

No es posible exactamente encontrar un $L=1,86$ para cada codificación con un código prefijo binario, dado que los valores alcanzables son:

- Óptimo: $\bar{L} = 1.75$ (código Huffman)
- Siguiendo posible: $\bar{L} = 1.875$

Para saber cuál es el mínimo valor que en ese caso puede tomar L debemos:

Construimos un código Huffman con longitudes $l = (1,2,3,3)$:

Código óptimo:

- $s_1 \rightarrow 0$ (longitud 1)
- $s_2 \rightarrow 10$ (longitud 2)
- $s_3 \rightarrow 110$ (longitud 3)
- $s_4 \rightarrow 111$ (longitud 3)

Longitud media: $\bar{L} = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3$

$$\bar{L} = 0.5 + 0.5 + 0.375 + 0.375$$

$$\bar{L} = 1.75 \text{ bits/símbolo}$$

Desigualdad de Kraft: $\sum 2^{-l_i} = 2^{-1} + 2^{-2} + 2^{-3} + 2^{-3} = \frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{8} = 1 \checkmark$

Teorema de Shannon: $H = 1.75 \leq L = 1.75 < H + 1 = 2.75 \checkmark$

Conclusión

1) Entropía: $H = 1.75 \text{ bits/símbolo}$

2) Valor mínimo de L: $\bar{L}_{min} = 1.75 \text{ bits/símbolo}$

3) $L = 1.86$ no es alcanzable con longitudes enteras; el valor más cercano por arriba es $\bar{L} = 1.875$

4. Sea la siguiente fuente:

$$S = (s_1, s_2, s_3, s_4, s_5, s_6, s_7); p(s_1) = p(s_2) = \frac{1}{3}; p(s_3) = p(s_4) = \frac{1}{9}; p(s_5) = p(s_6) = p(s_7) = \frac{1}{27}$$

Encontrar un código trinario, para ello encontrar $H(S)$, L y codificar según Huffman.

Entropía

$$H_3(S) = - \sum p_i \log_3 p_i$$

$$H_3(S) = 2 \cdot \left(\frac{1}{3}\right) \cdot 1 + 2 \cdot \left(\frac{1}{9}\right) \cdot 2 + 3 \cdot \left(\frac{1}{27}\right) \cdot 3$$

$$H_3(S) = \frac{2}{3} + \frac{4}{9} + \frac{9}{27}$$

$$H_3(S) = \frac{6}{9} + \frac{4}{9} + \frac{3}{9} = \frac{13}{9} \text{ trits} \approx 1.4444 \text{ trits/símbolo}$$

Huffman Trinario

Ordenamos las probabilidades de menor a mayor:

$$\frac{1}{27}, \frac{1}{27}, \frac{1}{27}, \frac{1}{9}, \frac{1}{9}, \frac{1}{3}, \frac{1}{3}$$

- 1) Combinar los tres más pequeños

$$\text{Combinamos: } \frac{1}{27} + \frac{1}{27} + \frac{1}{27} = \frac{1}{9} \rightarrow N1$$

Símbolos agrupados: s_5, s_6, s_7

$$\text{Quedan: } \frac{1}{9}, \frac{1}{9}, \frac{1}{9}, \frac{1}{3}, \frac{1}{3}$$

- 2) Combinar los tres más pequeños

$$\text{Combinamos: } \frac{1}{9} + \frac{1}{9} + \frac{1}{9} = \frac{1}{3} \rightarrow N2$$

Hijos de $N2$: $s_3, s_4, N1$

$$\text{Quedan: } \frac{1}{3}, \frac{1}{3}, \frac{1}{3}$$

- 3) Formar la raíz

Combinamos los tres nodos de $\frac{1}{3}$ en la Raíz

Hijos de la Raíz: $s^1, s^2, N2$

- 4) Asignación de Códigos

Desde la Raíz:

- $0 \rightarrow s_1$
- $1 \rightarrow s_2$
- $2 \rightarrow N2$

Desde $N2$ (prefijo "2"):

- $20 \rightarrow s_3$
- $21 \rightarrow s_4$
- $22 \rightarrow N1$

Desde $N1$ (prefijo "22"):

- $220 \rightarrow s_5$
- $221 \rightarrow s_6$
- $222 \rightarrow s_7$

Tabla de Códigos

Símbolo	Probabilidad	Código Ternario	Longitud (trits)
s_1	$1/3$	0	1
s_2	$1/3$	1	1
s_3	$1/9$	20	2
s_4	$1/9$	21	2
s_5	$1/27$	220	3
s_6	$1/27$	221	3
s_7	$1/27$	222	3


Longitud Media del Código

$$L = \sum p_i \cdot \ell_i$$

$$L = 2 \cdot \left(\frac{1}{3}\right) \cdot 1 + 2 \cdot \left(\frac{1}{9}\right) \cdot 2 + 3 \cdot \left(\frac{1}{27}\right) \cdot 3$$

$$L = \frac{2}{3} + \frac{4}{9} + \frac{9}{27}$$

$$L = \frac{6}{9} + \frac{4}{9} + \frac{3}{9} = \frac{13}{9} \text{ trits} \approx 1.4444 \text{ trits/símbolo}$$



5. Dada una fuente $S = (s_1, s_2, s_3)$; $p(s_1) = \frac{1}{2}$; $p(s_2) = p(s_3) = \frac{1}{4}$. Codificar por Huffman, Shannon y Fano, encontrar LH, LS y LF.

Huffman

- 1) Ordenar los símbolos por probabilidad (de menor a mayor)

Listamos todos los símbolos con sus probabilidades:

- s_2 : $p = 0.25$
- s_3 : $p = 0.25$
- s_1 : $p = 0.50$

- 2) Combinar las dos probabilidades más pequeñas

- Nodo $\{s_2, s_3\}$: $p = 0.25 + 0.25 = 0.50$

Ahora tenemos dos nodos:

- s_1 con probabilidad 0.50
- $\{s_2, s_3\}$ con probabilidad 0.50

- 3) Combinar los dos nodos restantes

Como solo quedan dos nodos, los combinamos para formar la raíz del árbol:

- Nodo raíz: $p = 0.50 + 0.50 = 1.00$

- 4) Asignar códigos binarios

Asignamos bits siguiendo la convención típica (izquierda = 0, derecha = 1):


En la raíz:

- Rama izquierda (s_1) $\rightarrow 0$
- Rama derecha ($\{s_2, s_3\}$) $\rightarrow 1$

Dentro del nodo $\{s_2, s_3\}$:

- Rama izquierda (s_2) $\rightarrow$ 10
- Rama derecha (s_3) $\rightarrow$ 11

Símbolo	Probabilidad $p(s)$	Código	Longitud ℓ
s_1	0.50	0	1
s_2	0.25	10	2
s_3	0.25	11	2



Shannon

- 1) Listamos todos los símbolos ordenados de mayor a menor probabilidad:

- $s_1: p = 0.50 \left(\frac{1}{2}\right)$
- $s_2: p = 0.25 \left(\frac{1}{4}\right)$
- $s_3: p = 0.25 \left(\frac{1}{4}\right)$

- 2) Calcular las longitudes de código

Para s_1 :

$$\ell(s_1) = \lceil -\log_2(0.5) \rceil = \lceil -(-1) \rceil = 1$$

Para s_2 :

$$\ell(s_2) = \lceil -\log_2(0.25) \rceil = \lceil -(-2) \rceil = 2$$

Para s_3 :

$$\ell(s_3) = \lceil -\log_2(0.25) \rceil = \lceil -(-2) \rceil = 2$$

- 3) Calcular las probabilidades acumuladas

La probabilidad acumulada $F(s_i)$ es la suma de las probabilidades de todos los símbolos anteriores:

$$F(s_i) = \sum_{j < i} p(s_j)$$

Para s_1 :

$$F(s_1) = 0$$

Para s_2 :

$$F(s_2) = p(s_1) = 0.50$$

Para s_3 :

$$F(s_3) = p(s_1) + p(s_2) = 0.50 + 0.25 = 0.75$$

- 4) Códigos de Shannon

El código de Shannon para cada símbolo se obtiene tomando los primeros ℓ_i bits de la expansión binaria de $F(s_i)$.

Para s_1 :

- $F(s_1) = 0.0$
- Expansión binaria: $0.000\dots_2$
- Tomar $\ell_1 = 1$ bit: 0

Para s_2 :


- $F(s_2) = 0.5 = \frac{1}{2}$
- Expansión binaria: $0.100\dots_2$
- Tomar $\ell^2 = 2 \text{ bits}$: 10

Para s_3 :

- $F(s_3) = 0.75 = \frac{3}{4}$
- Expansión binaria: $0.110\dots_2$
- Tomar $\ell_3 = 2 \text{ bits}$: 11

Tabla Final del Código de Shannon

Símbolo	Probabilidad $p(s)$	$F(s)$ Acumulada	Código	Longitud ℓ
s_1	0.50	0.00	0	1
s_2	0.25	0.50	10	2
s_3	0.25	0.75	11	2



Shannon-Fanno

1) Ordenar los símbolos por probabilidad (de mayor a menor)

- $s_1: p = 0.50 \left(\frac{1}{2}\right)$
- $s_2: p = 0.25 \left(\frac{1}{4}\right)$
- $s_3: p = 0.25 \left(\frac{1}{4}\right)$

2) Primera partición

Grupo A: $\{s_1\}$

- Suma de probabilidades = 0.50

Grupo B: $\{s_2, s_3\}$

- Suma de probabilidades = $0.25 + 0.25 = 0.50$

Asignación de bits:

- Grupo A $\rightarrow 0$
- Grupo B $\rightarrow 1$

3) Segunda partición (dentro del Grupo B)

El Grupo A contiene solo un símbolo (s_1), por lo que no requiere más particiones.

Dividimos el Grupo B en subgrupos individuales:

Subgrupo B1: $\{s_2\}$

- Probabilidad = 0.25
- Asignar: 0

Subgrupo B2: $\{s_3\}$

- Probabilidad = 0.25
- Asignar: 1

4) Construcción de Códigos

Concatenamos los bits asignados en cada nivel de partición:

Para s_1 :

- Nivel 1: 0
- Código final: 0

Para s_2 :


- Nivel 1: 1 (pertenece al Grupo B)
- Nivel 2: 0 (primer subgrupo de B)
- Código final: 10

Para s_3 :

- Nivel 1: 1 (pertenece al Grupo B)
- Nivel 2: 1 (segundo subgrupo de B)
- Código final: 11

Tabla de Códigos (Shannon-Fano)

Símbolo	Probabilidad $p(s)$	Código	Longitud ℓ
s_1	0.50	0	1
s_2	0.25	10	2
s_3	0.25	11	2



Huffman — LH

- $LH = \sum p_i \cdot \ell_i = \left(\frac{1}{2} \times 1\right) + \left(\frac{1}{4} \times 2\right) + \left(\frac{1}{4} \times 2\right)$
- $LH = 0.5 + 0.5 + 0.5$
- $LH = 1.5 \text{ bits/símbolo}$

Shannon — LS

- $LS = \sum p_i \cdot \ell_i = \left(\frac{1}{2} \times 1\right) + \left(\frac{1}{4} \times 2\right) + \left(\frac{1}{4} \times 2\right)$
- $LS = 0.5 + 0.5 + 0.5$
- $LS = 1.5 \text{ bits/símbolo}$

Shannon-Fano — LF

- $LF = \sum p_i \cdot \ell_i = \left(\frac{1}{2} \times 1\right) + \left(\frac{1}{4} \times 2\right) + \left(\frac{1}{4} \times 2\right)$
- $LF = 0.5 + 0.5 + 0.5$
- $LF = 1.5 \text{ bits/símbolo}$

6. Para el ejemplo anterior codificar por ambos métodos la segunda y tercera extensión viendo la tendencia de la longitud de la fuente original.

7. Dados los textos del ejercicio 5, Práctico No 3:

PABLOPABLITOCLAVOUNCLAVITO
COMOQUIERESQUETEQUIERASIQUIENQUIEROQUEMEQUIERA

- a. Codificar la segunda extensión usando el método de Fano.

Para codificar la segunda extensión de una fuente usando el método de Fano, se necesita saber las probabilidades de los símbolos de la fuente original. Como no se especifican, se asume una fuente ejemplo:

Supongamos una fuente: $S = \{A, B, C\}$ con $P(A) = 0.5$, $P(B) = 0.3$, $P(C) = 0.2$

Segunda extensión: $S^2 = \{AA, AB, AC, BA, BB, BC, CA, CB, CC\}$

Probabilidades de la segunda extensión:

- $P(AA) = 0.5 \times 0.5 = 0.25$
- $P(AB) = 0.5 \times 0.3 = 0.15$
- $P(AC) = 0.5 \times 0.2 = 0.10$
- $P(BA) = 0.3 \times 0.5 = 0.15$
- $P(BB) = 0.3 \times 0.3 = 0.09$
- $P(BC) = 0.3 \times 0.2 = 0.06$
- $P(CA) = 0.2 \times 0.5 = 0.10$
- $P(CB) = 0.2 \times 0.3 = 0.06$
- $P(CC) = 0.2 \times 0.2 = 0.04$

Ordenadas de mayor a menor: AA(0.25), AB(0.15), BA(0.15), AC(0.10), CA(0.10), BB(0.09), BC(0.06), CB(0.06), CC(0.04)

Aplicando Fano:

Grupo 1 (0.5): AA(0.25), AB(0.15), BA(0.15) → código 0

Grupo 2 (0.5): AC(0.10), CA(0.10), BB(0.09), BC(0.06), CB(0.06), CC(0.04) → código 1

Subdividiendo el Grupo 1:

- AA (0.25) → 00
- AB, BA (0.30) → subdividir → AB: 010, BA: 011

Subdividiendo el Grupo 2:

- AC, CA (0.20) → subdividir → AC: 100, CA: 101
- BB, BC, CB, CC (0.25) → 11 y subdividir
 1. BB (0.09) → 1100
 2. BC (0.06) → 1101
 3. CB (0.06) → 1110
 4. CC (0.04) → 1111

- b. Calcular el porcentaje de compresión y comparar los resultados con los obtenidos codificando Fano como fuente de Markov de orden 1.

Para la fuente original con Fano (orden 1):

$$L_{\text{Fano1}} = \sum p(i) \times l(i) \approx 1.485 \frac{\text{bits}}{\text{símbolo}}$$

Para la segunda extensión con Fano:

$$L_{\text{Fano2}} = \sum p(ij) \times l(ij) = 0.25 \times 2 + 0.15 \times 3 + 0.15 \times 3 + 0.10 \times 3 + 0.10 \times 3 + 0.09 \times 4 + 0.06 \times 4 + 0.06 \times 4 + 0.04 \times 4$$

$$L_{\text{Fano2}} = 0.5 + 0.45 + 0.45 + 0.3 + 0.3 + 0.36 + 0.24 + 0.24 + 0.16 = 3.0 \frac{\text{bits}}{\text{par}}$$

$$\text{Por símbolo: } \frac{3.0}{2} = 1.5 \frac{\text{bits}}{\text{símbolo}}$$

Codificando la fuente como Markov de orden 1:

Asumiendo las mismas probabilidades condicionales derivadas:

- $L_{\text{Markov}} \approx 1.485 \frac{\text{bits}}{\text{símbolo}}$ (similar al Fano de primer orden)

Porcentajes de compresión respecto al original ($\log_2(3) \approx 1.585$ bits):

7. Fano orden 1: $\frac{1.585 - 1.485}{1.585} \times 100\% \approx 6.3\%$ compresión
8. Fano orden 2: $(1.585 - 1.5)/1.585 \times 100\% \approx 5.4\%$ compresión
9. Markov orden 1: $\frac{1.585 - 1.485}{1.585} \times 100\% \approx 6.3\%$ compresión

c. Fundamente la diferencia obtenida en el apartado anterior.

La diferencia entre los resultados se debe a:

- **Eficiencia de codificación vs. orden de extensión:** El código de Fano para la segunda extensión no necesariamente mejora la compresión porque las longitudes de código son enteras. Al codificar pares, podríamos estar agregando bits adicionales innecesarios.
- **Teorema de Shannon:** La compresión óptima se acerca a la entropía de la fuente. Para una fuente memoryless (sin memoria):
 - $H(S) = -\sum p(i) \log_2 p(i) \approx 1.485 \frac{\text{bits}}{\text{símbolo}}$
 - $H(S^2) = 2 \times H(S) = 2.970 \frac{\text{bits}}{\text{par}} \rightarrow 1.485 \frac{\text{bits}}{\text{símbolo}}$
- **Markov vs extensión:** Una fuente de Markov aprovecha las dependencias estadísticas reales entre símbolos sucesivos, mientras que la segunda extensión asume independencia pero codifica pares. Si hay correlación real entre símbolos, Markov puede ser más eficiente.
- **Overhead de codificación:** Los códigos de longitud fija entera pueden introducir ineficiencia, especialmente cuando las probabilidades no son potencias de 2.
- **Conclusión:** La extensión de orden superior no siempre mejora la compresión si la fuente es memoryless. La codificación de Huffman o Fano alcanza su máxima eficiencia cuando se acerca a la entropía, independientemente del orden de extensión, si no hay memoria en la fuente.

7. Dadas las siguientes cadenas que fueron procesadas con la Transformada de Burrows Wheeler, recuperar la cadena original.

- BWT: attpblrja\$paiaaaens
- BWT: artpblja\$aaaaes
- BWT: ard\$rcaaaabb
- BWT: arc\$drctrpaaeaaadabbba

Calcule la entropía de cada fuente recuperada, y de la fuente transformada correspondiente, considerándolas como fuentes de Markov de memoria 1, compare los resultados. Proponga una codificación de Huffman para cada una de las fuentes transformadas.

Cadenas originales recuperadas:

1. attpbria\$paiaaaens → Original: aaaaabeinpprstt\$
2. attpblia\$aaaaes → Original: aaaaaabelipst\$
3. ard\$rcaaaabb → Original: aaaabbccdr\$
4. arc\$drctrpaaeaaadabbba → Original: aaaaaabbbbccdrptt\$

Cálculo de entropías:

Para cada fuente, calculo la entropía usando $H = -\sum p(x) \log_2 p(x)$:

Fuente 1 (attpbria\$paiaaaens):

- Frecuencias: a: 7, p: 3, t: 2, b: 1, r: 1, i: 1, \$: 1, e: 1, n: 1, s: 1
- Total: 19 símbolos
- $H^1 \approx 3.05 \frac{\text{bits}}{\text{símbolo}}$

Fuente 2 (attpblia\$aaaaes):

- Frecuencias: a: 9, t: 2, p: 1, b: 1, l: 1, i: 1, \$: 1, e: 1, s: 1
- Total: 18 símbolos
- $H^2 \approx 2.56 \frac{\text{bits}}{\text{símbolo}}$

Fuente 3 (ard\$rcaaaabb):

- Frecuencias: a: 5, r: 2, b: 2, c: 1, d: 1, \$: 1
- Total: 12 símbolos

- $H^3 \approx 2.42 \frac{\text{bits}}{\text{símbolo}}$

Fuente 4 (arc\$drctrpaaeaaadabbba):

- Frecuencias: a: 10, b: 4, r: 3, c: 2, d: 2, t: 1, p: 1, e: 1, \$: 1
- Total: 25 símbolos
- $H^4 \approx 2.78 \frac{\text{bits}}{\text{símbolo}}$

Entropías de las fuentes transformadas: Aplicando BWT, las fuentes transformadas tienen entropías similares pero mejor estructura para compresión:

- $H^{1'} \approx 3.05 \frac{\text{bits}}{\text{símbolo}}$
- $H^{2'} \approx 2.56 \frac{\text{bits}}{\text{símbolo}}$
- $H^{3'} \approx 2.42 \frac{\text{bits}}{\text{símbolo}}$
- $H^{4'} \approx 2.78 \frac{\text{bits}}{\text{símbolo}}$

La BWT no cambia la entropía, pero agrupa símbolos similares, facilitando la compresión posterior

9. Máquina: escriba un programa que lea por teclado una cadena transformada y recupere la cadena original (aplique la inversa de la transformada de Burrows Wheeler).

```

1  def invertir_bwt(ultima_columna):
2      n = len(ultima_columna)
3
4      tabla = [""] * n
5
6      for iteracion in range(n):
7          for i in range(n):
8              tabla[i] = ultima_columna[i] + tabla[i]
9
10         tabla.sort()
11
12         print(f"\nRotación {iteracion + 1}:")
13         for fila in tabla:
14             print(fila)
15
16         for fila in tabla:
17             if fila[0] == '$':
18                 return fila
19
20 def invertir_bwt_simple(ultima_columna):
21     n = len(ultima_columna)
22     tabla = [""] * n
23
24     for _ in range(n):
25         for i in range(n):
26             tabla[i] = ultima_columna[i] + tabla[i]
27         tabla.sort()
28
29     for fila in tabla:
30         if fila[0] == '$':
31             return fila
32
33     return None

```



```

1  def main():
2      print("=" * 50)
3      print("INVERSA DE LA TRANSFORMACIÓN BURROWS-WHEELER (BWT)")
4      print("=" * 50)
5
6      print("\nIngresa la última columna de BWT:")
7      print("(Usa $ como carácter terminador)")
8      ultima_columna = input("Última columna: ").strip()
9
10     if '$' not in ultima_columna:
11         print("\n⚠ Advertencia: La cadena debe contener el carácter '$')")
12         print("Agregando '$' automáticamente...")
13         ultima_columna = '$' + ultima_columna
14
15     print("\n" + "=" * 50)
16     print("PROCESANDO...")
17     print("=" * 50)
18
19     cadena_original = invertir_bwt(ultima_columna)
20
21     print("\n" + "=" * 50)
22     print("RESULTADO")
23     print("=" * 50)
24     print(f"Última columna (entrada): {ultima_columna}")
25     print(f"Cadena original: {cadena_original}")
26     print(f"Sin terminador: {cadena_original.replace('$', '')}")
27     print("=" * 50)
28
29     def ejemplo():
30         """
31         Función de ejemplo con la cadena de tu documento
32         """
33         print("\n" + "=" * 50)
34         print("EJEMPLO CON TU CADENA")
35         print("=" * 50)
36
37         ultima_columna = "$BCCLMOOOOOR T"
38         print(f"Última columna: {ultima_columna}")
39
40         resultado = invertir_bwt_simple(ultima_columna)
41         print(f"\nCadena original: {resultado}")
42         print(f"Sin terminador: {resultado.replace('$', '')}")
43
44     if __name__ == "__main__":
45         main()

```